

Distant Reading 2: linguistique computationnelle

Vers le quantitatif

Simon Gabay



Du corpus

Le matériau

Comme toutes les sciences, la stylistique s'appuie sur des preuves, qu'il s'agit de collecter, puis d'analyser. Ces preuves sont de divers ordres:

1. Énonciation
2. Textualité
3. Syntaxe
4. Rythme et sonorités
5. Lexique
6. Figures

L'intuition computationnelle

1. L'informatique peut-elle nous aider à accélérer ces relevés?
2. L'informatique peut-elle nous aider à relever autre choses?

Les approches computationnelle de la langue, mais aussi de la linguistique, font le pari que oui.

Le corpus

Une approche computationnelle est quantitative, et donc fondée sur des fréquences, mais aussi des différences de fréquence. Celles-ci sont calculées sur des textes, et le choix de ces textes détermine la fiabilité des résultats.

Une approche quantitative requiert une fondation solide de la base de données et dans l'analyse et la catégorisation des données.

A quantitative perspective requires a very solid foundation in the preparation of the data base and in the analysis and categorisation of the data.

Jucker, "Corpus pragmatics", 2018

Typologie

On va donc avoir recours à un corpus. Aarts (2011) en propose une typologie simple:

- *Balanced corpora*: on fournit une image plus ou moins représentative d'une langue, d'état de langue, d'un champ...
- *Full-text corpora*: on fournit des textes complets
- *Parallel corpora*: on fournit des textes en plusieurs langues, ou de plusieurs versions d'une même langue (par exemple des dialectes)

Il existe évidemment une tension entre:

- Peu de données richement contextualisées
- Des corpus de grande taille, mais avec peu d'information supplémentaire

Balancement

Aarts propose en 2011 la notion de *balanced corpus*, mais la création de tels corpus a commencé dans les années 60:

- Le *London-Lund Corpus of Spoken English* (LLC)
- Le *Brown Corpus* de l'anglais américain écrit
- Le *Lancaster-Oslo-Bergen* (LOB) de l'anglais britannique écrit.

Nous avons aussi désormais des corpus diachroniquement balancés:

- Le *Early Modern English Medical Texts* (EMEMT)

Représentativité

Un corpus est pensé comme représentatif de la variété de langue qu'il est supposé représenter si les découvertes basées sur son contenu peuvent être généralisées à ladite variété de langue.

A corpus is thought to be representative of the language variety it is supposed to represent if the findings based on its contents can be generalized to the said language variety.

Leech, "The State of the Art in Corpus Linguistics", 1991

Représentativité (II)

Mais la représentativité est un concept fluide, très lié aux questions de recherche:

- Faut-il un corpus général?
- Faut-il un corpus spécialisé? Si oui comment?

Toute prétention à la représentativité et au balancement doit être interprétée en termes relatifs

Linguistique de corpus vs textométrie

La textométrie ne se confond pas avec la linguistique de corpus. Toutes deux fondent leurs investigations sur un corpus numérique, dont la constitution est déterminante. Comme son nom l'indique, la linguistique de corpus poursuit un objectif de description et de modélisation de la langue. La textométrie, centrée sur le texte, a pu être mobilisée par diverses sciences humaines (histoire, littérature, sciences politiques...).

[La textométrie] se caractérise notamment par certains calculs fondateurs, statistiques (les spécificités, les cooccurrences) ou non (les segments répétés, les concordances), et accorde une place fondamentale au « retour au texte » (bien outillé dans les logiciels) pour interpréter les unités (généralement des mots) sélectionnées par les calculs.

Pincemin, "Sémantique interprétative et textométrie", 2012.

Textométrie vs stylométrie

La lexicométrie s'est d'abord définie comme étude du vocabulaire, avant qu'on ne parle de logométrie – comme étude globale d'un discours – ou encore de textométrie, comme analyse d'un texte. Le terme de stylométrie, quant à lui, fonde sa spécificité dans la caractérisation d'une écriture.

Magri-Mourgues, "Stylistique et statistiques. Le corpus textuel et hyperbase", 2016,

Les outils

Plus que le mot

Evidemment, ces recherches s'appuient sur le texte numérisé, et donc les mots qui le constitue. En plus de la recherche plein texte, nous pouvons désormais compter sur des outils qui ajoutent un surcroît d'information, et permettent des recherche jusqu'à présent inédites.

Ces informations ne sont cependant pas simples à ajouter, car elles dépendent de choix complexes qui ont un impact très fort sur les résultats lors de la fouille de texte.

Le token

Le token (en français "jeton") n'est pas un mot, c'est une entité lexicale. C'est une chaîne de caractères (*string*) entre deux délimiteurs. Ces délimiteurs sont eux-mêmes une chaîne de caractères (usuellement virgule, point-virgule... éventuellement précédés d'un espace insécable), dont le choix est (relativement libre).

Prenons l'exemple de "aujourd'hui". Nous avons un mot qui est composé de:

1. un token: *aujourd'hui*
2. deux tokens: *aujourd'* et *hui*
3. trois tokens: *aujourd*, *'* et *hui*

Le lemmatiseur

- Faire passer de la forme fléchie à son lemme.
- Ce lemme est une forme canonique. Dire qu'elle n'est pas fléchie est problématique: le masculin n'est-il pas aussi fléchi? (cf. notion de flexion zéro)
- Il faut faire la différence entre le lemme et le mot vedette de l'entrée du dictionnaire
- Il faut s'appuyer sur un référentiel, comme *Morphalou*, car il faut éviter qu'un même mot ait deux lemmes (*œil*, *clef* ...)

token
Je
mange
une
pomme

token	Lemme
Je	je
mange	manger
une	un
pomme	pomme

Le POS tagger

On parle de *POS* pour *part of speech*, "partie du discours". Un *POS tagger* permet donc d'accoler à chaque token sa nature grammaticale.

Pour cela on utilise un jeu d'étiquettes précis: **N** pour le substantif, **Aj** pour l'adjectif, **D** pour le déterminant... Il en existe plusieurs, et il faut choisir, ce qui n'est pas facile.

Il existe des cas limites, comme l'adjectivation (du participe passé, du participe présent...): comment trancher entre étiquetage morphologique et morpho-syntactique?

En plus de la nature, on peut rajouter des informations supplémentaires: le nombre, le genre, le mode, le temps, la personne...

token	Lemme
Je	je
mange	manger
une	un
pomme	pomme

token	Lemme	CATTEX	UDpos	EAGLES	MULTEX
Je	je	PROper	PRON	PRON_PER	Pp
mange	manger	VERcjg	VERB	V_GVRB	Vv
une	un	DERndf	DET	ART	Dn
pomme	pomme	NOMcom	NOUN	NN	Nc

.


Token
de
ce
trait
perçant
mon
coeur
est
blessé

Token	Lemme	POS	Morphologie
de	de	PRE	MORPH=empty
ce	ce	DETdem	NOMB.=s GENRE=m
trait	trait	NOMcom	NOMB.=s GENRE=m
perçant	percer	VERppa	NOMB.=s GENRE=m
mon	mon	DETpos	PERS.=1 NOMB.=s GENRE=m
coeur	cœur	NOMcom	NOMB.=s GENRE=m
est	être	VERcjg	MODE=ind TEMPS=pst PERS.=3 NOMB.=s
blessé	blessar	VERppe	NOMB.=s GENRE=m

Le parseur

Le parseur permet de faire de l'analyse syntaxique – en anglais on parle de *syntactic parsing*. Il s'agit désormais, en plus du lemme et de la POS de récupérer la fonction dans la phrase.

Cette approche s'appuie beaucoup sur la grammaire d'arbres adjoints (TAG, *Tree-adjointing grammar*) qui représente la phrase sous la forme de graph.



Source: [Wikipedia](#)

Exemple

| Il aime le pain et le vin.


Comment analyser la coordination?

| Il aime le pain et le vin .


| Il aime le pain et le vin .

| Il aime le pain et le vin .

DeepXML



UD



CoNLL

	token	Lemme	POS 1	POS 2	Morph	Rel.	Fonction
1	Il	il	CL	CLS	s=suj	2	suj
2	aime	aimer	V	V	t=pst	0	root
3	le	le	D	DET	s=def	4	det
4	pain	pain	N	NC	s=c	2	obj
5	et	et	C	CC	s=c	4	coord
6	le	le	D	DET	s=def	7	det
7	vin	vin	N	NC	s=c	5	dep_coord
8	.	.	PONCT	PONCT	_	2	ponct

Les autres taggeurs

On parle de plus en plus d' *Inside–outside–beginning* (IOB) format pour les entités nommées.

Une entité nommée est une expression linguistique référentielle. Elle renvoie la plupart du temps à une personne ou un lieu.

Exemple:

| Livia Jeanneret va à Los Angeles

Token	Entité
Livia	
Jeanneret	
va	
à	
Los	
Angeles	

Token	Entité
Livia	PER-B
Jeanneret	PER-I
va	0
à	0
Los	LOC-B
Angeles	LOC-I