Cours Stylistique numérique

Introduction à la stylistique

Simon Gabay

Lemmatiser

Définition

> La lemmatisation désigne un **traitement lexical** apporté à un texte en vue de son analyse. Ce traitement consiste à appliquer aux **occurrences des lexèmes** sujets à flexion (en français, verbes, substantifs, adjectifs) **un codage** renvoyant à leur entrée lexicale commune (« **forme canonique** » enregistrée dans les dictionnaires de la langue, le plus couramment), que l'on désigne sous le terme de lemme.

Fonctionnement global

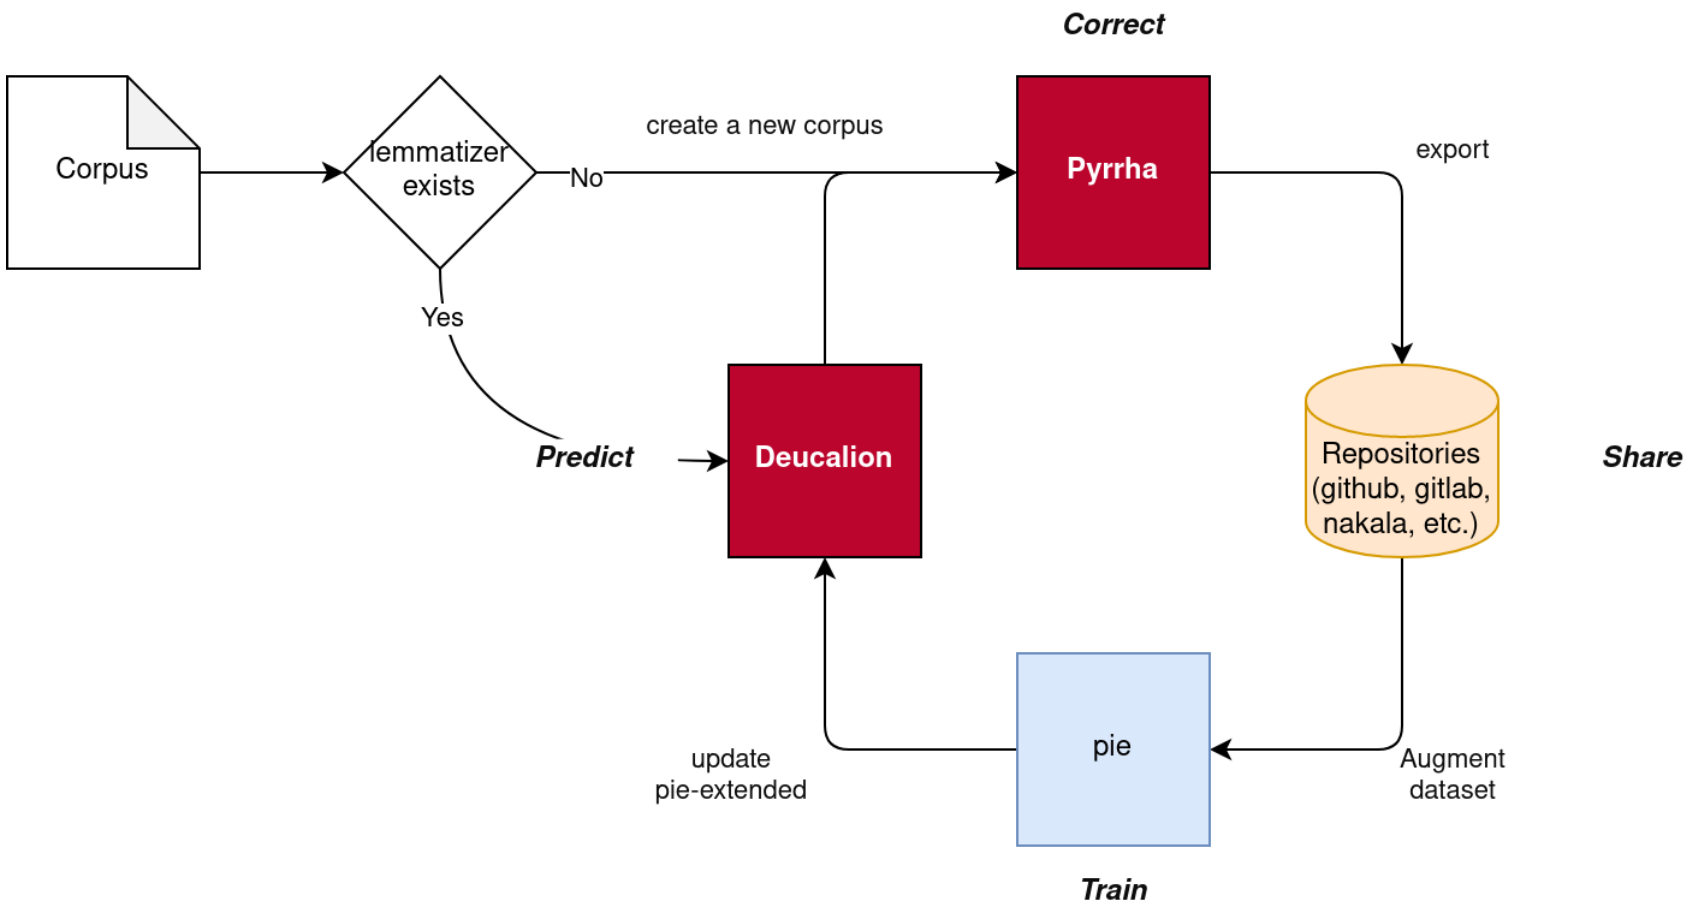

Lemmatiser

Texte	**Les**	**étoiles**	**luisent**	**dans**	**la**	**nuit**	**noire**	**.**
Texte	Les	étoiles	luisent	dans	la	nuit	noire	.

2 formes sur 8 (25%) ne peuvent être lemmatisées que d'une seule manière, quelque soit le contexte (en français moderne): la ponctuation (`.`) et la préposition `dans`).

Lemmatiser: quelques cas

- *comtesse*
- *Quelques-uns*
- *Celui-ci*
- *Lui-même*
- *va-t-il*
- *Jehan*
- *Jeanne*
- *Vespasianus*
- *bien que*
- *parce que*
- *afin que*
- *François de La Rochefoucauld*

Lemmatiser: quelques cas

- *comtesse* -> Féminin? ou masculin?
- *Quelques-uns*
- *Celui-ci*
- *Lui-même*
- *va-t-il* -> Que faire du -*t*- euphonique?
- *Jehan* -> normaliser les noms
- *Jeanne* -> Féminiser les noms propres
- *Vespasianus* -> Moderniser les noms?
- *bien que* ->
- *parce que* -> comment analyser *parce*?
- *afin que* -> comment analyser *afin*?
- *François de La Rochefoucauld* -> *le* ou *La*

Lemmatiser: quelques cas

- *Il me demande à moi*
- *Un retour éclatant*
- *Une âme affligée*
- *Les .X. commandements*
- *le pater noster*
- *Oeuf*
- *Égypte*
- *s'enfuir*
- *Le Père R.*
- *aux*
- *dudit*
- *il ne leur manquera rien* vs *leur vif éclat*

Lemmatiser: quelques cas

- *Il me demande à moi* -> moi=*je* ou *moi*
- *Un retour éclatant* -> adj ou participe présent?
- *Une âme affligée* -> adj ou participe passé?
- *Les .X. commandements* -> que faire des chiffres?
- *le pater noster* -> comment lemmatiser les emprunts?
- *Oeuf* -> comment traiter les ligatures?
- *Égypte* -> garder les accents sur les majuscules?
- *s'enfuir* -> que faire des pronominaux (*abaisser* vs *s'abaisser*?)
- *Le Père R.* -> Que faire des noms abrégés?
- *aux* -> lemme composé *à_le*
- *dudit* -> lemme composé "triple" *de_ledit*?
- *il ne leur manquera rien* -> pronom *il* vs déterminant possessif *leur*

Préparer les données

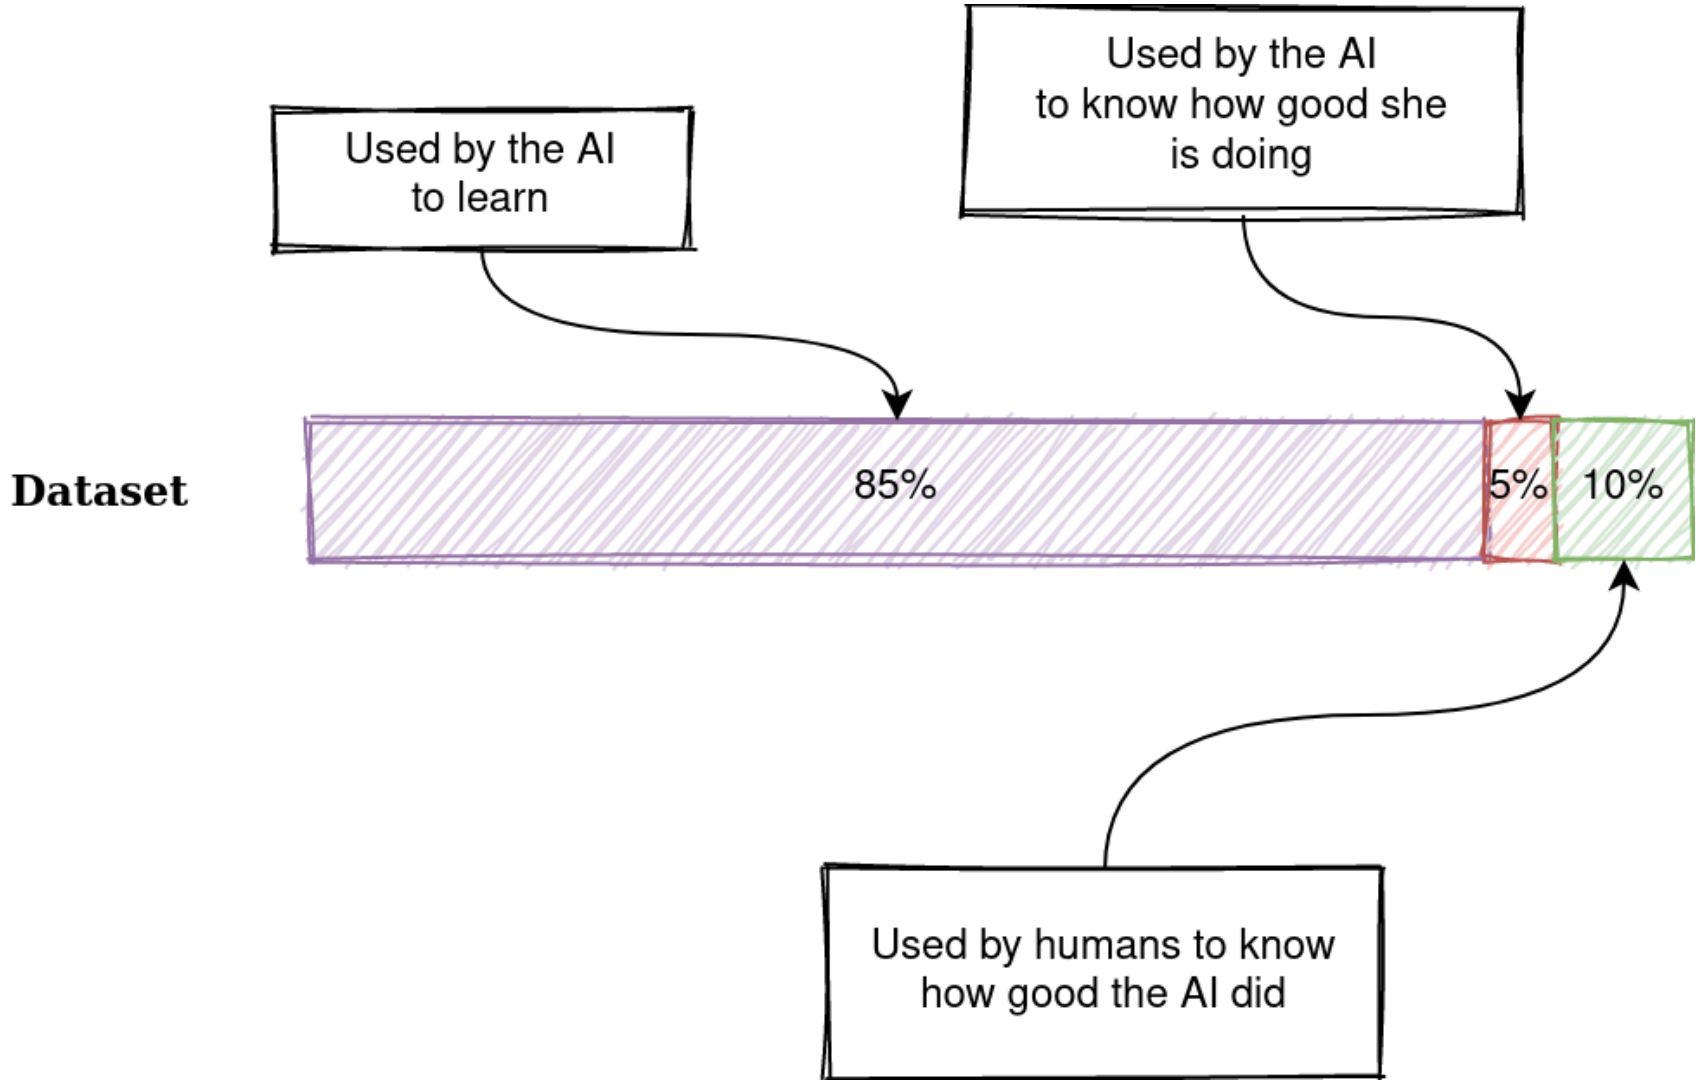

Cycle d'apprentissage

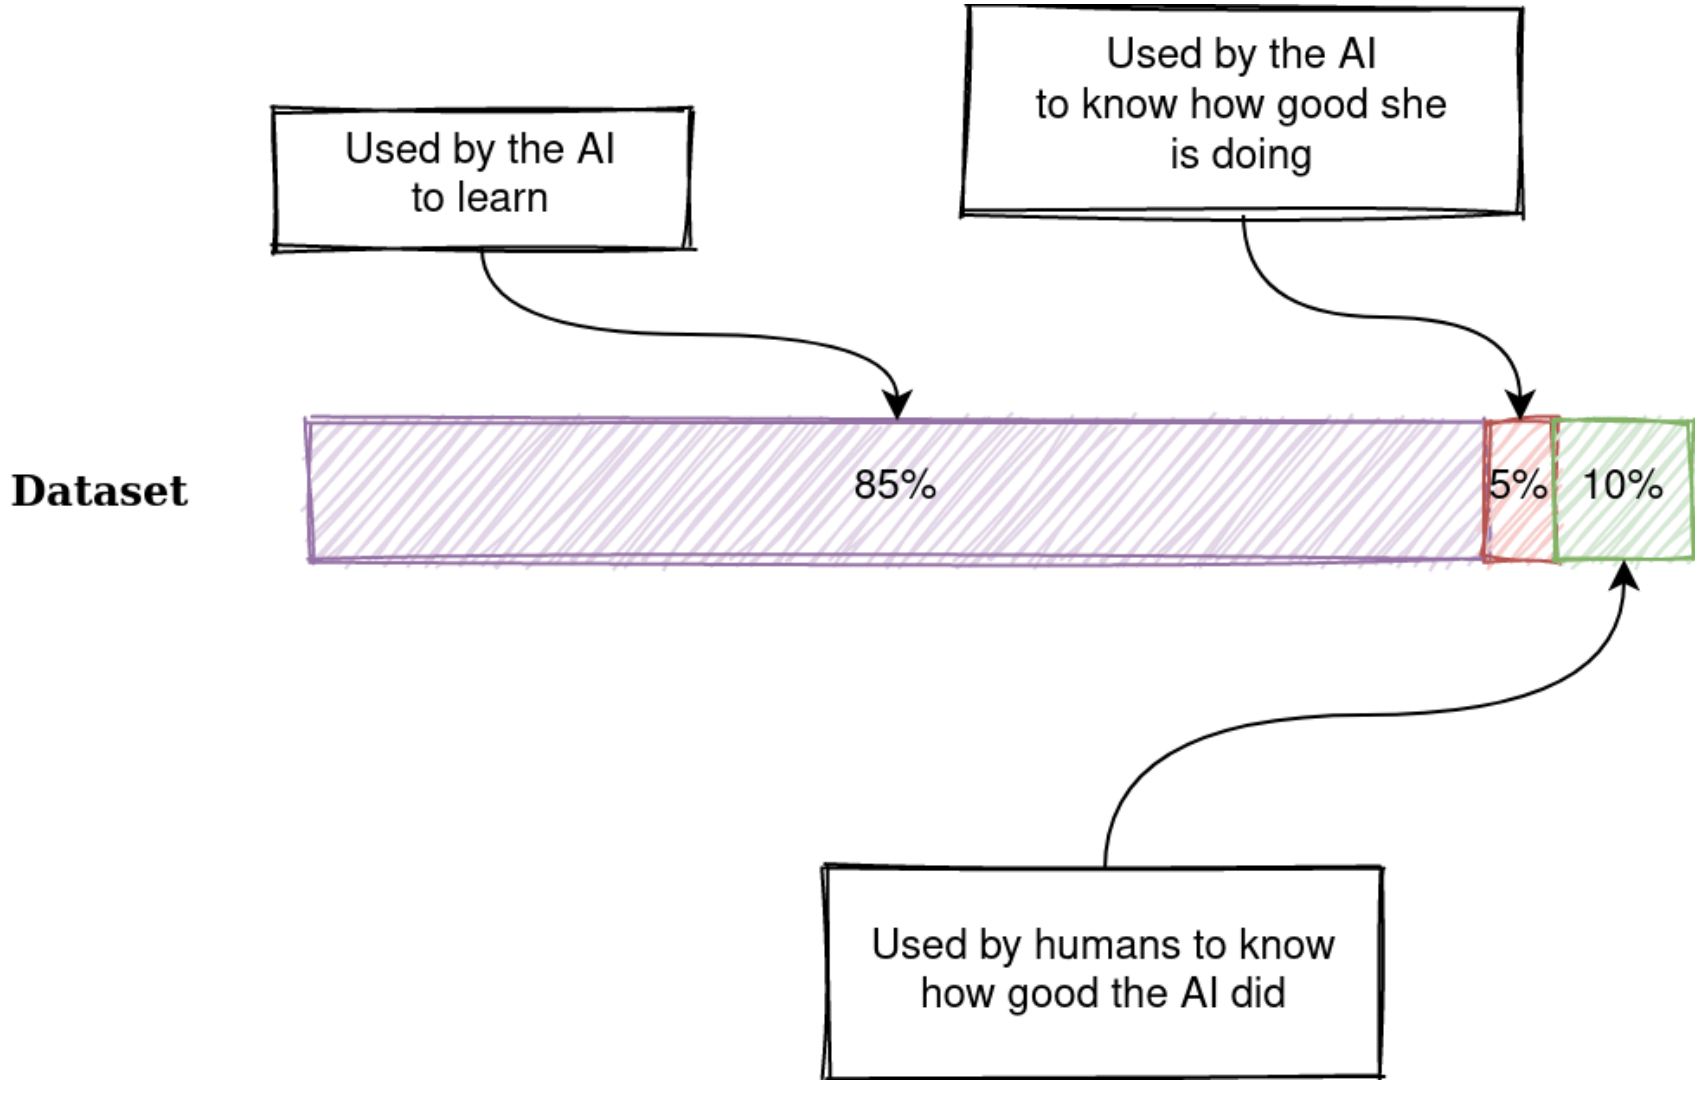

Fonctionnement du lemmatiseur (classe)

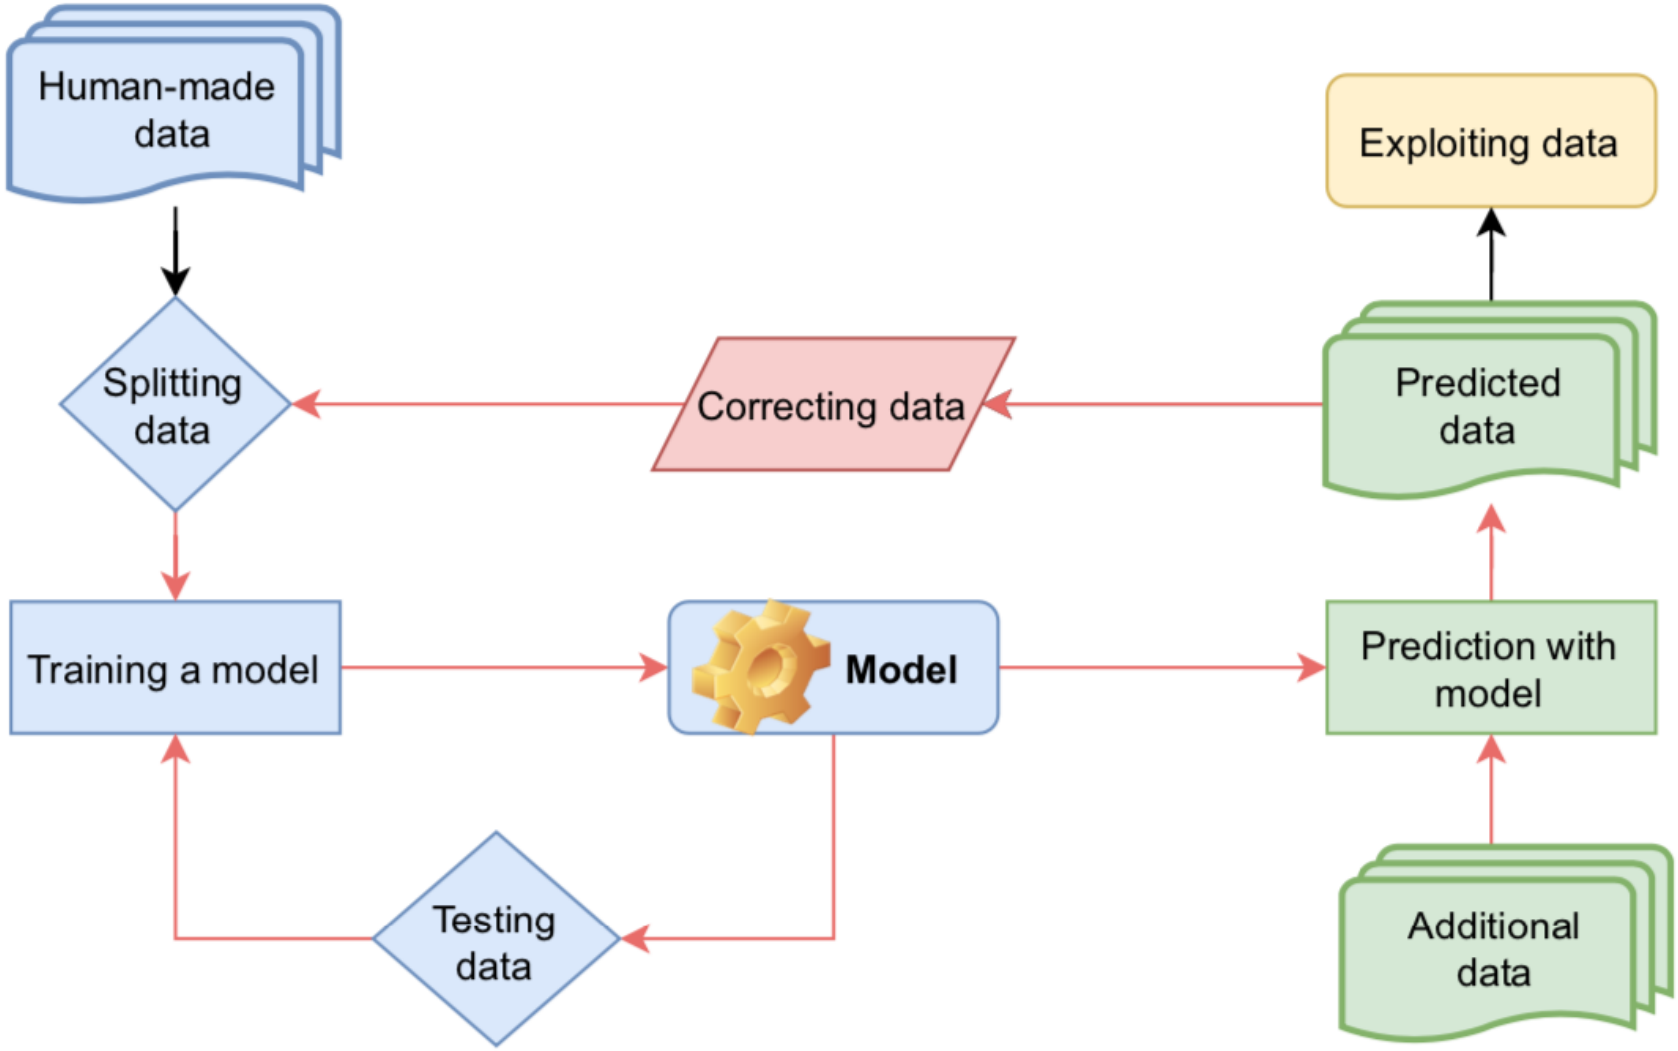

Fonctionnement du lemmatiseur (génération de séquence)

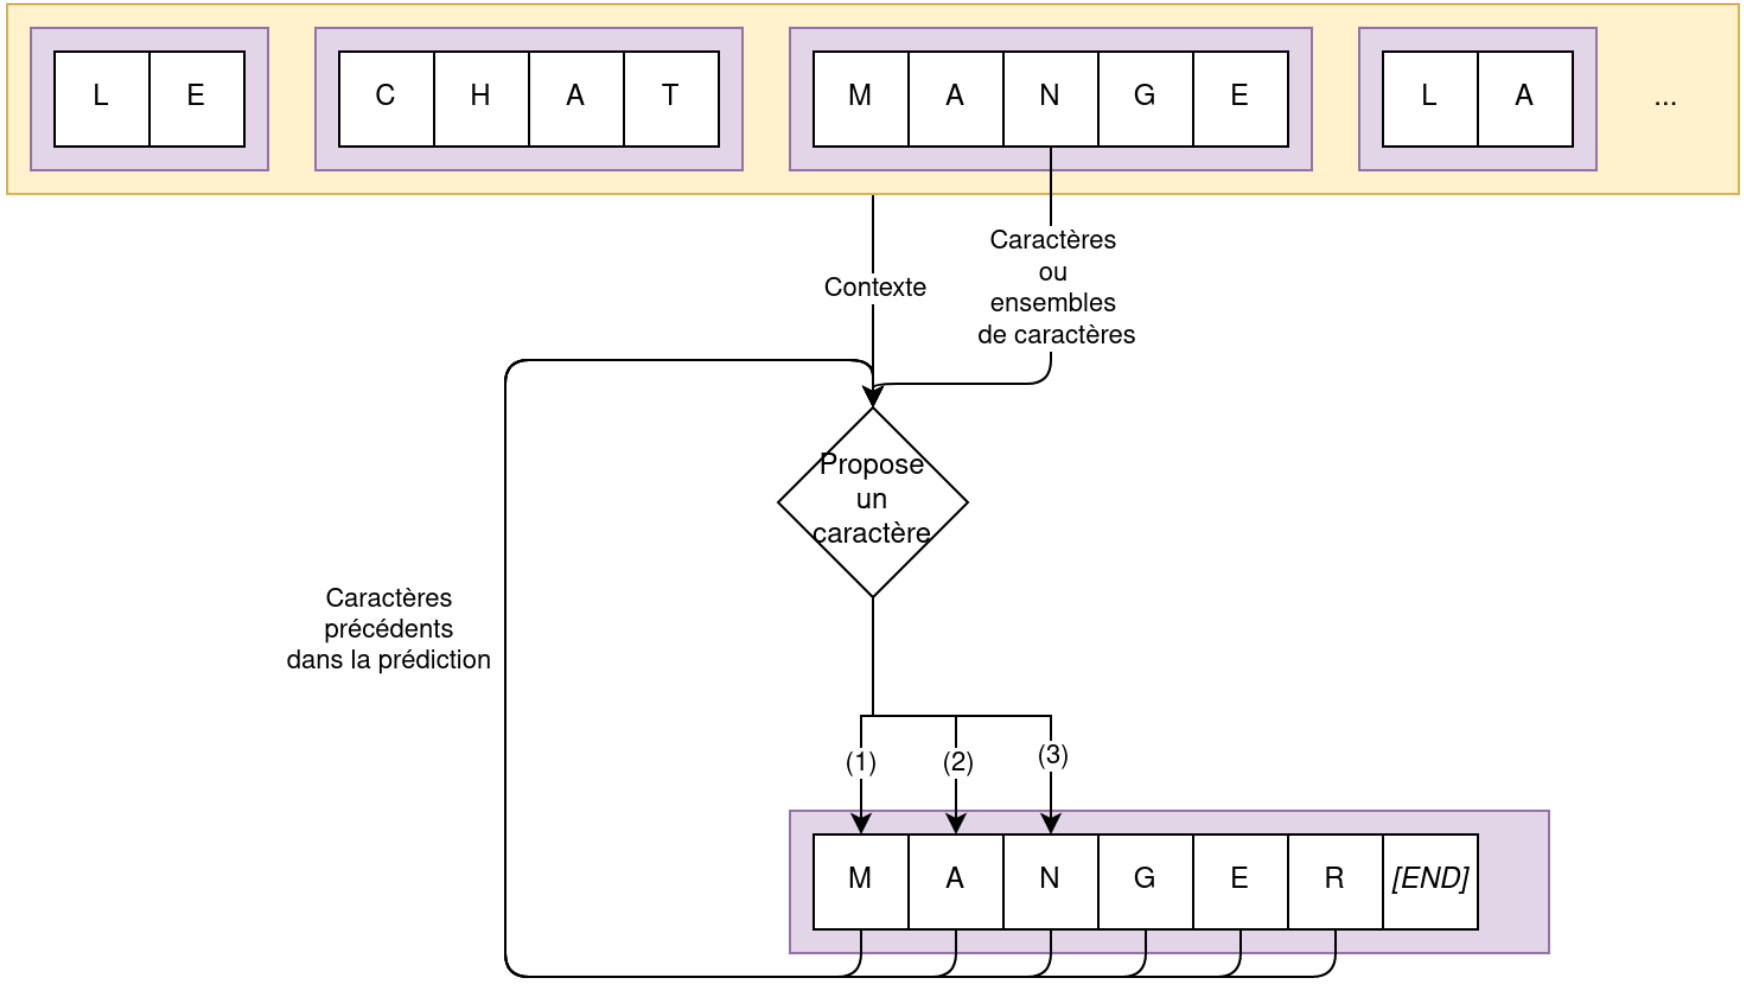

Parties du discours

Parties du discours: quelques cas

- *la Fortune*
- *un retour éclatant*
- *mon Dieu* vs *le dieu Jupiter*
- *parce que*
- *vive les vacances*
- *voici*
- *18 ans* vs *ses 18 ans*
- *le pater noster*
- *le Père R.*

Parties du discours: quelques cas

- *la Fortune* -> `NOMpro` ou `NOMcom`
- *un retour éclatant*
- *mon Dieu* (détermination non pertinente -> `NOMpro`) vs *le dieu Jupiter* (`NOMcom`)
- *parce que* -> `ADVgen` par analogie (*bien que*)
- *vive les vacances* -> `VERcjg`
- *voici* -> `VERcjg`
- *18 ans* `DETcar NOMcom` vs *ses 18 ans* `DETpos ADJcar NOMcom`
- *le pater noster* -> `ETR`
- *le Père R.* -> `ABR`

Parties du discours: quelques cas

- *aux*
- *duquel*
- *Monsieur de La Rochefoucauld*
- *Mesnil montant* (Ménilmontant)
- *là-dessus*
- *premier*
- *dernier*

Parties du discours: quelques cas

- *aux* -> `PRE.DETdef`
- *duquel* -> `PRE.DETrel` ou `PRE.PROrel` ou `PRE.PROint` en fonction du contexte
- *Monsieur de La Rochefoucauld* -> `NOMcom PRE NOMpro NOMpro`
- *Mesnil montant* (Ménilmontant) `NOMpro VERppa`
- *là-dessus* -> `ADVgen PONfbl ADVgen`
- *premier* -> `ADJord`
- *dernier* -> `ADJqua`

Morphologie

Morphologie: quelques cas

- *je*
- *me*
- *moi*
- *mes*
- *vous êtes odieux*
- *il est clair*
- *J'ai mangé*
- *rien*
- *Julien Sorel*

Morphologie: quelques cas

- *je* -> `CAS=n` nominatif
- *me* -> `CAS=r` régime direct
- *moi*-> `CAS=i` régime indirect
- *mes* -> `PERS.=1|NOMB.=s` ou `PERS.=1|NOMB.=p`
- *vous êtes odieux* -> Féminin ou masculin? *vous* `GENRE=x`
- *il est clair* -> Masculin ou neutre? `NOMB.=s|GENRE=n` ou `NOMB.=s|GENRE=m`?
- *J'ai mangé* -> `VERcjg MODE=ind|TEMPS=pst` + `VERppe`
- *rien* -> `MORPH=empty`
- *Julien Sorel*

Sources

Thibault Clérice, Matthias Gille Levenson, Lucence Ing, Ariane Pinche, Simon Gabay, Jean-Baptiste Camps, «Lemmatiser des textes et corriger l'annotation grâce à l'apprentissage profond avec Pyrrha », *Humanistica 2021*, Mai 2021, Rennes, France. ⟨hal-03224112⟩.