Cours Stylistique numérique

Le réemploi

Simon Gabay

Introduction

Définition

On parle de *text reuse*, en français «réutilisation de texte».

La question de savoir ce qu'on «réutilise» est importante:

- Exactement les mêmes termes
- À peu près les mêmes termes
- Un peu la même idée

Matteo Romanello, Aurélien Berra et Alexandra Trachsel proposent la définition suivante: il s'agit d'une «réitération significative d’un texte, généralement au-delà de la simple répétition du langage courant» (Romanello et al. 2014)

Applications

Dans le cadre pédagogique, on va surtout utiliser l'analyse de réemploi pour la détection de plagiat.

En philologie, on va surtout s'intéresser:

- Aux citations;
- Aux paraphrases;
- Aux allusions.

Evidemment, le degré de difficulté varie en fonction de la distance entre la source son réemploi.

Viral texts

Le Projet *Viral texts* étudie le réemploi dans la presse américaine du XIXe s. (cf. https://viraltexts.org).

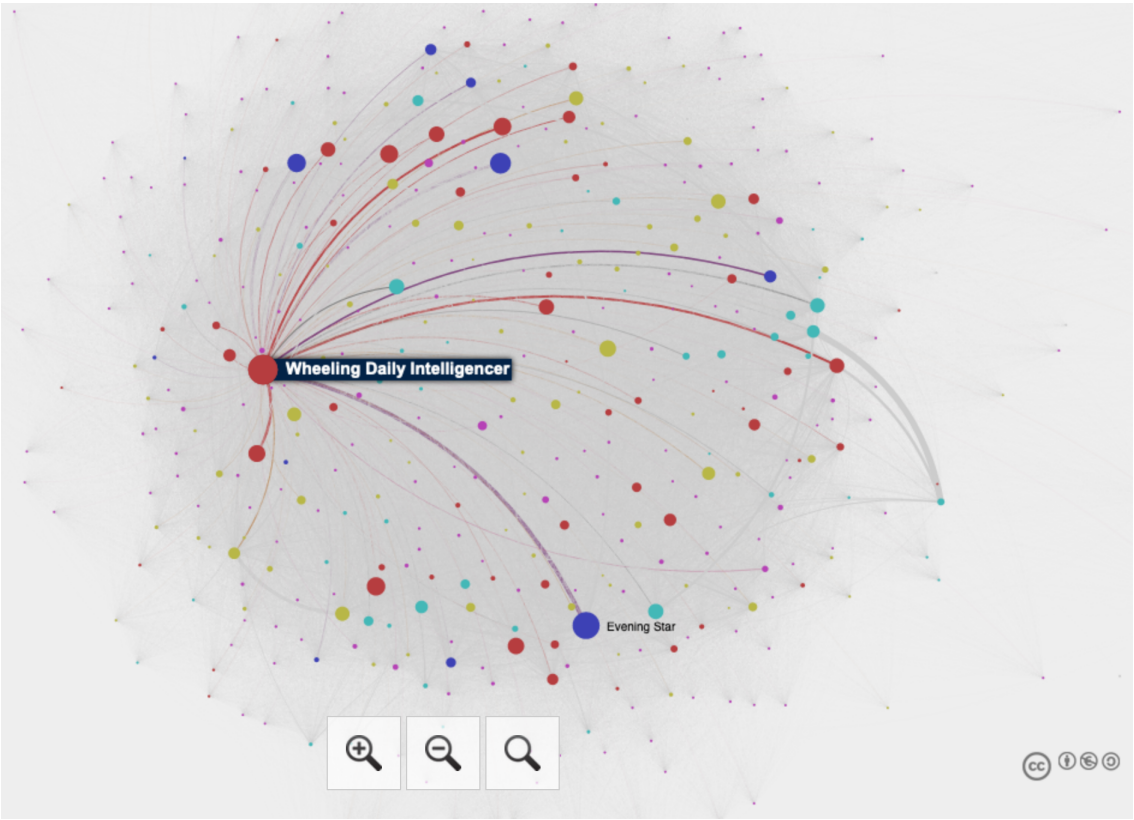

Il est possible, par exemple, de voir quel journal influence quel autre, en regardant qui copie qui.

Nombreuses applications

L'analye de réemploi est devenue une tâche courante du Traitement Automatique des Langues (TAL). De nombreux outils existent, programmés dans différents langages:

- `textReuse` (en R)
- `TRACER` (en Java)
- `Passim` (en scala)
- ...

La difficulté de prise en main varie énormément d'un outil à un autre.

Les outils ne sont pas toujours maintenus (cf. TRACER).

Problèmes

Problèmes I: la variation graphique

Les spécialistes des sciences humaines savent que les langues ont connu différents états de langue

1	2	3	4
Tu	estois	a	Lion
Tu	étais	à	Lyon

Comment faire pour aligner un texte qui est manifestement le même, mais pas écrit strictement de la même manière?

Problèmes II: Ajout/suppression

Si la chaîne de texte n'est pas deux fois strictement la même, est-ce le même texte? Le problème d'alignement se complexifie:

1	2	?	3	4
Tu	estois	hier	a	Lion
Tu	estois		a	Lion

À Partir de combien d'ajout ou de suppression considérons-nous qu'il s'agit d'un autre texte?

Problèmes III: la reformulation

Si la chaîne de texte est (partiellement) reformulée, est-ce le même texte?

1	2	3	4
Tu	estois	a	Lion
Tu	es	a	Lion
Tu	estois	dans	la capitale des Gaules
Tu	es	dans	la capitale des Gaules

1. Comment identifier qu'il s'agit de la même chose?
2. Est-ce vraiment la même chose?

Solutions

N-grams

Il est important de découper le texte en *n-grams* (n-grammes). Un *n-gram* est une sous-séquence de *n* éléments construite à partir d'une séquence donnée. Ainsi la phrase:

> S'ils furent ma blessure, ils seront mon Achille, S'ils furent mon venin, le scorpion utile

Je peux faire des *n-grams* de 3 tokens:

1. s'ils furent ma
2. furent ma blessure
3. ma blessure ils
4. ...

Evidemment la taille du *n-gram* (ici des *3-grams* ou trigrammes) influe sur les résultats.

Skip grams

Afin de ne pas manquer des réemplois légèrement différents, on peut utiliser des *skip grams*, c'est-à-dire des *n-grams* non consécutifs

> S'ils furent ma blessure, ils seront mon Achille, S'ils furent mon venin, le scorpion utile

Avec un *skip* de 2:

1. s'ils blessure mon
2. furent ils achille
3. ma seront s'ils
4. ...

Evidemment la taille du *skip gram* influe aussi sur les résultats.

Distance de Jaccard

Une fois obtenue les *n-grams* il faut les comparer. Pour cela on utilise (par exemple) la distance de Jaccard (« coefficient de communauté »).

Cette distance est utilisée pour évaluer la similarité entre deux échantillons. Elle mesure le rapport entre:

- le cardinal (la taille) de l'intersection (la présence de tokens identiques dans les deux échantillons) des ensembles (les deux échantillons comparés)
- le cardinal (la taille) de l'union (la somme des tokens) des ensembles (les deux échantillons comparés)

Distance de Jaccard

1. le cardinal de l'intersection des ensembles (source: Wikipedia)

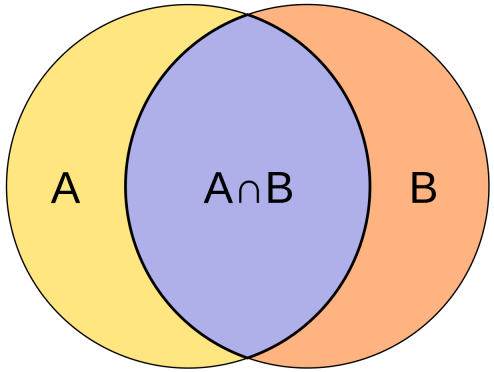

2. le cardinal de l'union des ensembles (source: Wikipedia)

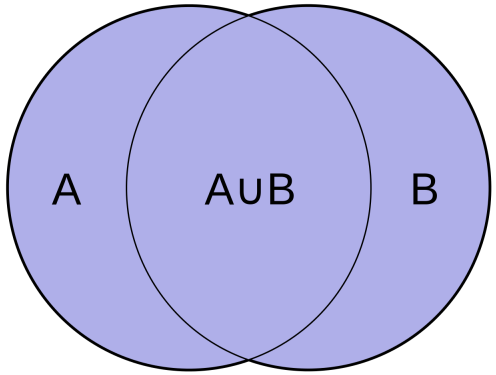

Intersection over union

L'index de Jaccard (*J*) est noté:

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|}.$$

On entend parfois la formule *intersection over union* (IoU). C'est une méthode très utilisée en vision par ordinateur (*computer vision*).

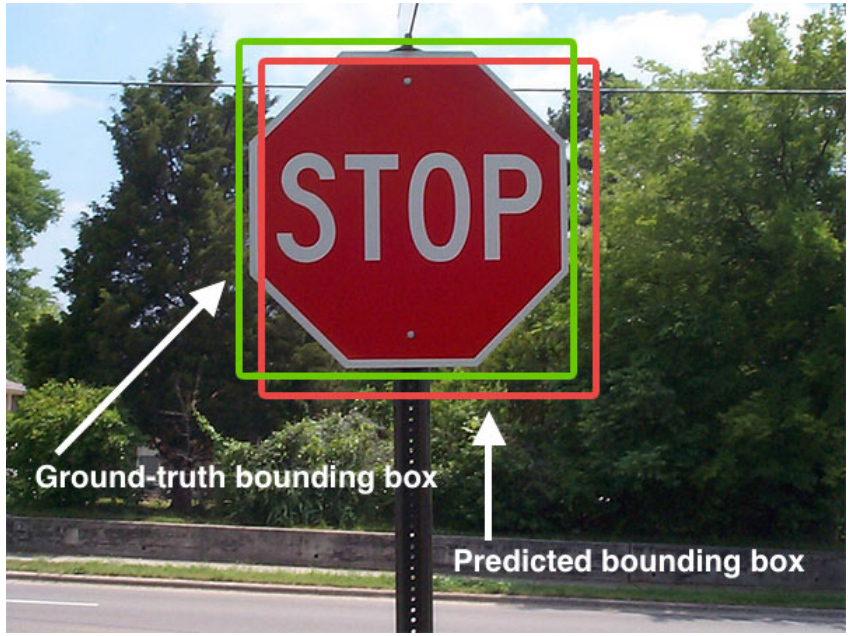

Source: Wikipedia

Minhash

Le problème de cette technique est qu'elle est particulièrement chronophage: il faut comparer tous les tokens/n-grammes. On peut aller plus vite avec *MinHash*.

1. On utilise une *hash function* qui, à partir d'une donnée fournie en entrée, transforme le texte en une série de clefs numériques.
2. Ce sont ces empreintes numériques (ou *hash*), optimisées pour l'analyse computationnelle, que nous allons comparer

Le taille de ce que l'on veut hacher va du plus simple (un mot) au plus compliqué (une œuvre). Ce hachage peut être réversible ou non (cf. cryptographie)

Exemple de "hachage"

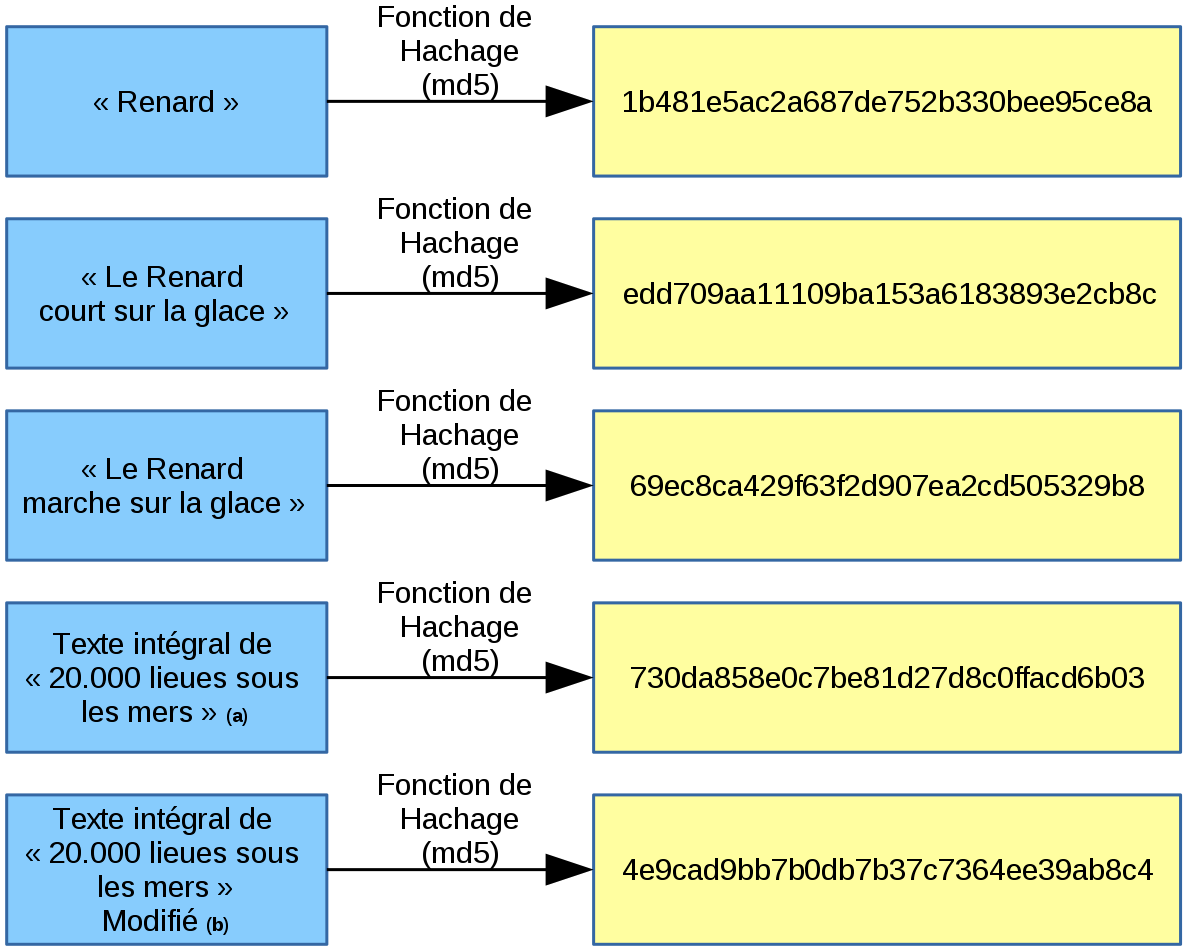

Source: Wikipedia

Locality sensitive hashing

Le hachage n'est cependant pas optimum si les empreintes ne reflètent pas les proximités. Pour corriger ce défaut, on utilise le *Locality sensitive hashing* (LSH).

Le LSH utilise un algorithme de "recherche des plus proches voisins". On peut ainsi évacuer de la somme des comparaisons à faire toutes les paires dont l'empreinte est divergeante, et gagner du temps, ce qui est utile pour les gros corpus.