Cours Stylistique numérique

# Les modèles de langue et les champs lexicaux

Simon Gabay

# Introduction

# Le TAL

Approche multidisciplinaire (linguistique, informatique...) dont les objets sont très proches de la philologie computationnelle

Le TAL a pour but de créer des outils de traitement de la langue naturelle pour diverses applications. On parle de tâche: la lemmatisation, l'annotation des parties du discours...

## Trois grands objectifs:

1. Analyser: extraction d'information, analyse de sentiment, fouille de texte...
2. Génération: génération de dialogue (pour les chatbots), journalisme automatique...
3. transformation: traduction automatique, résumé automatique, simplification de texte...

# Nouveau paradigme du TAL

Le passage à des approches neuronales a deux implications fortes:

1. L'apparition des modèles de langue
2. Le besoin de corpus bruts massifs pour entraîner ces modèles

Actuellement on entend beaucoup par de modèles BERT — reconnaissable avec leur nom qui finit en "-BERT" comme *CamemBERT* pour le français contemporain, ou *d'AlemBERT* pour le français d'Ancien Régime (préclassique et classique).

Ces modèles s'appuient sur des corpus: OSCAR pour *CamemBERT* et FreEM max pour *d'AlemBERT*.

Cf. https://freem-corpora.github.io/corpora/max/

# Le modèle de langue

## Défintion

> Un modèle de langue est une distribution de probabilités sur les séquences de mots

Il a deux utilités:

- trouver le mot suivant le plus probable d'après les mots qui le précèdent
- trouver le mot masqué selon les mots qui le précède et lui succède

# Le modèle statistique

## Il s'agit de compter

Le système le plus simple est celui du "modèle unigramme" Ainsi la probabilité *P* de trois mots *w* est la suivante:

$P_1(w_1w_2w_3) = P(w_1)P(w_2)P(w_3)$

-> quelle est la fréquence d'un mot?

Il existe des modèles plus complexes dits "bigrammes" ou "n-grams":

$P_2(w_1w_2w_3) = P(w_1|\#)P(w_2|w_1)P(w|w_2)$

-> quelle est la probabilité que ce soit un mot $w_1$, étant donné le mot qui le précède $w_2$?

# Le modèle prédictif

### Il s'agit de prédire

Etant donnée une position et un contexte, est-il possible de prédire quel est le mot qui suit? (cf. les recherches sur google).

Il existe deux types de contexte:

- le contexte gauche
- le contexte droit et gauche (dit "complet")

# Représenter un mot

Un mot est une somme d'information: il est composé de lettres, de morphèmes, d'un rôle syntaxique, de sèmes...

- un mot avec la lettre *w* en français dit quelque chose de l'origine de ce mot (origine germanique)
- un finale en -*ai*- dit autre chose de ce mot (imparfait ou conditionnel)
- la racine *chat* de *chatte* dit quelque chose du champ lexical (au sens fort de léxème) de ce mot
- *il aime son chat* dit quelque chose sur la nature du référent (animé...)

Il est possible de présenter cette information sous forme linguistique, comme nous venons de le faire, mais on peut aussi le faire sous la forme d'un vecteur (en gros un nombre plus ou moins long)

# Le vecteur dit *one-hot*

Prenons deux phrases: *Il aime Jeannette* et *Elle aime Raoul*.

La représentation vectorielle la plus simple consiste à se doter d'un vocabulaire de taille *n* et à utiliser pour représenter le *i*-ième mot du vocabulaire un vecteur où toutes les dimensions sont nulles sauf la *i*-ième qui vaut 1.

| | il | aime | Jeannette | elle | Raoul |
|---|---|---|---|---|---|
| il | 1 | 0 | 0 | 0 | 0 |
| aime | 0 | 1 | 0 | 0 | 0 |
| Jeannette | 0 | 0 | 1 | 0 | 0 |

- il -> `[1 0 0 0 0]`
- aime -> `[0 1 0 0 0]`

## *index-based encoding*

Il est possible de simplifier ce système (et réduire la taille de la matrice) avec un *index-based encoding*, qui assigne comme valeur à chaque mot sa position dans le lexique

| Lexique | Clef |
|---|---|
| il | 1 |
| aime | 2 |
| Jeannette | 3 |
| elle | 4 |
| Raoul | 5 |

- Il aime Jeannette -> `[1 2 3]`
- Elle aime Raoul -> `[4 2 5]`

## Hypothèse distributionnelle

Le problème avec les valeurs de l'index ou des vecteurs *one hot*, c'est

- qu'elles sont arbitraires: *il* ( `1` ) et *elle* ( `4` ) ont des valeurs moins proches qu'*il* ( `1` ) et *Jeannette* ( `3` ). C'est un problème.
- qu'elles sont toujours distantes de 1, alors que *il* et *elle* sont plus proches que *Raoul* et *aimer*

On parle d'"hypothèse distributionnelle" : deux mots sont similaires s'ils apparaissent dans les mêmes contextes. Ainsi "médecin" et "doceur" apparaissent dans des contextes similaires.

> You shall know a word by the company it keeps! (Firth 1957)

> If A and B have almost identical environments we say that they are synonyms. (Harris 1954)

## *embeddings* (ou "plongement") non contextuel

Avec de la sémantique distributionnelle, il est possible d'évaluer la proximité des mots à partir des fréquences de collocation, et donc de proposer des vecteurs moins grands que les *one hot* (il -> `[1 0 0 0 0]`) et donc des valeurs moins arbitraires. Les *word embeddings* (ou "plongements lexicaux") reprennent et améliorent la "représentativité vectorielle".

| Lexique | Clef |
|---|---|
| il | 0.12 |
| aime | 0.23 |
| Jeannette | 0.76 |
| elle | 0.13 |
| Raoul | 0.66 |

# Word2vec

Word2vec n'est qu'un *lookup table*.

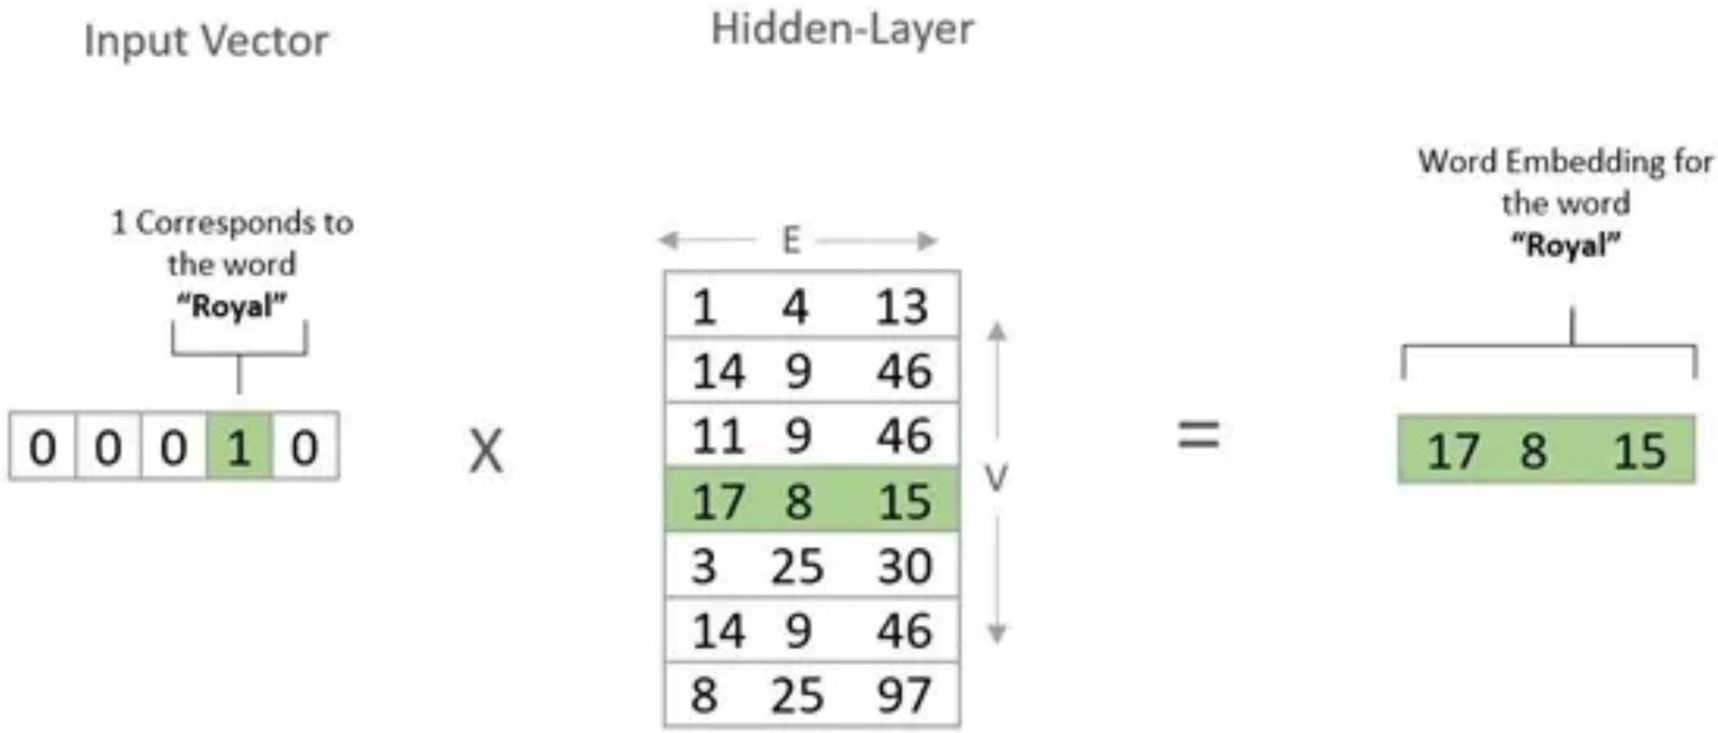


(Source)

Ou `V` et la taille du vocabulaire et `E` le nombre de dimensions.

# Qu'est-ce que cette couche cachée?

Une fonction de perte (*loss function*) va déterminer comment:

- trouver un mot en fonction de son contexte (CBOW)
- trouver un contexte en fonction d'un mot (skip-gram)

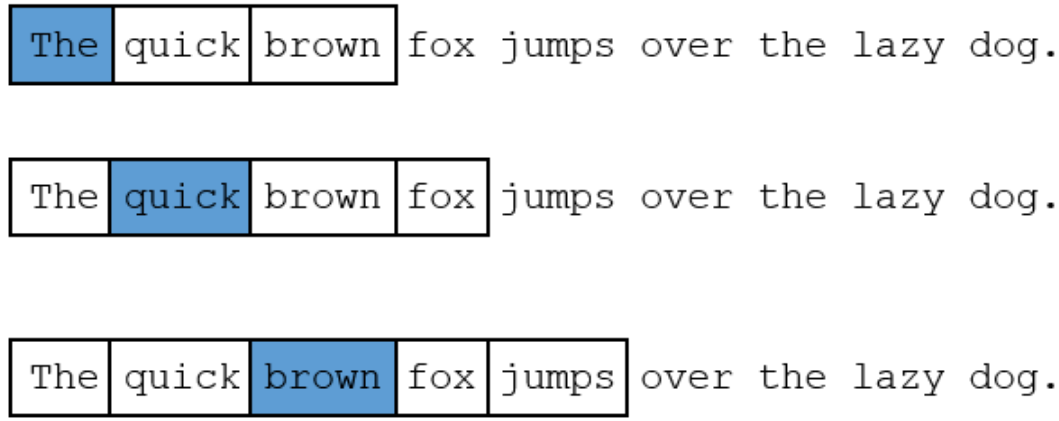

# Entrainement

Ici une architecture CBOW prenant un mot sur deux du contexte complet:

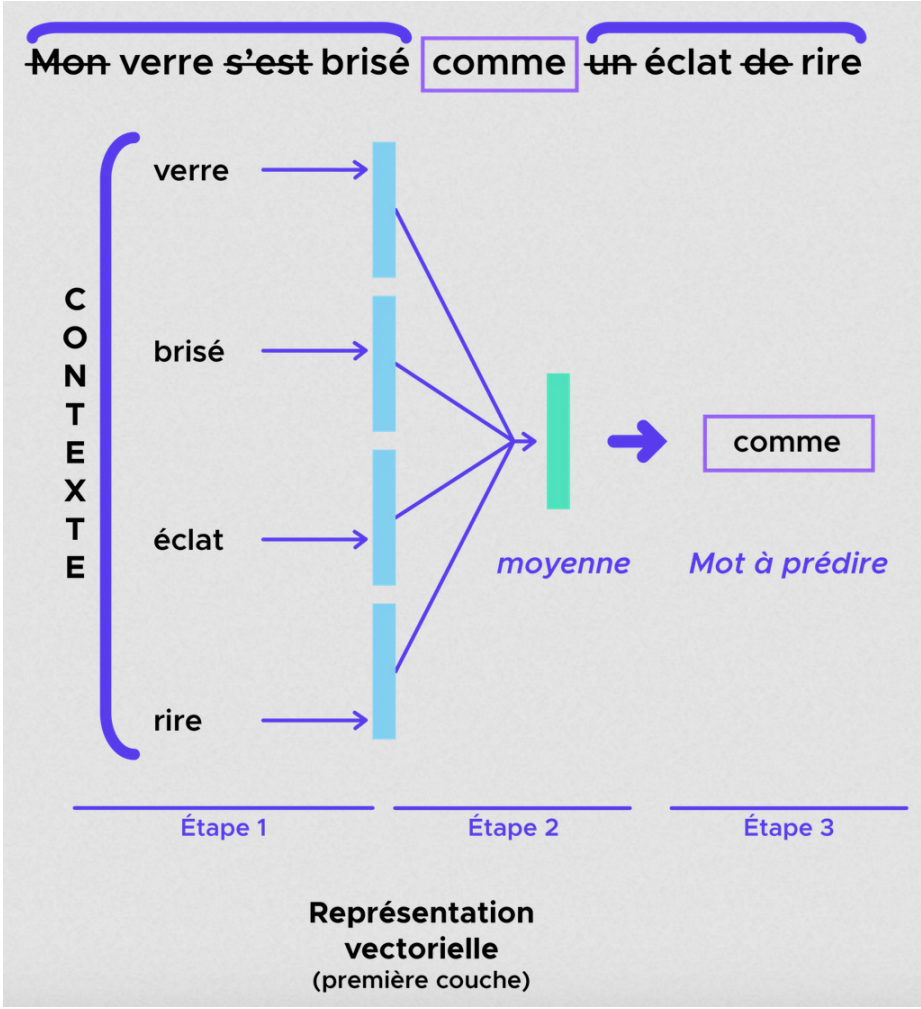


Source

# Réseau de neurone pour `word2vec`

Il s'agit d'un perceptron à une couche cachée (ici modèle CBOW):

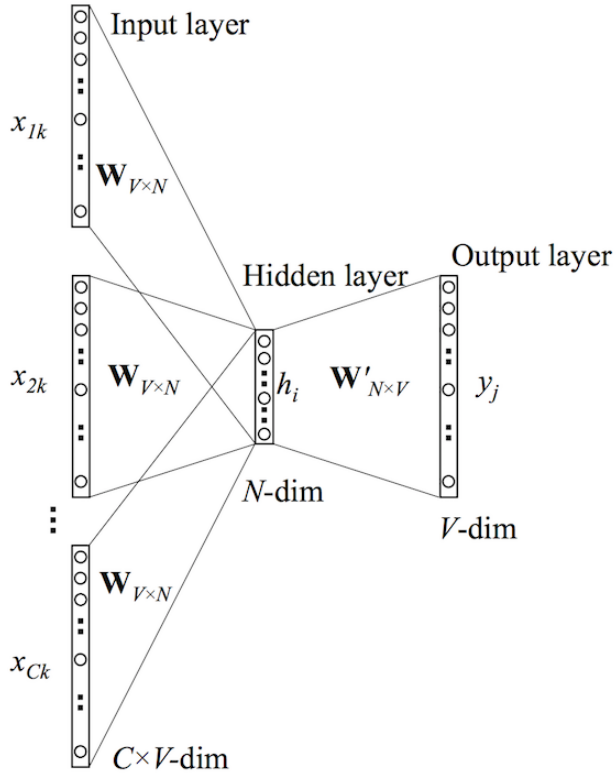


La manière la plus simple de commencer est une initialisation aléatoire des poids dans le réseau de neurone qui permet, étant donné les vecteurs pris en *input*, de prédire le mot en *output* via une fonction mathématique complexe.

# Réseau de neurone: détail de fonctionnement

Il s'agit d'un perceptron à une couche cachée

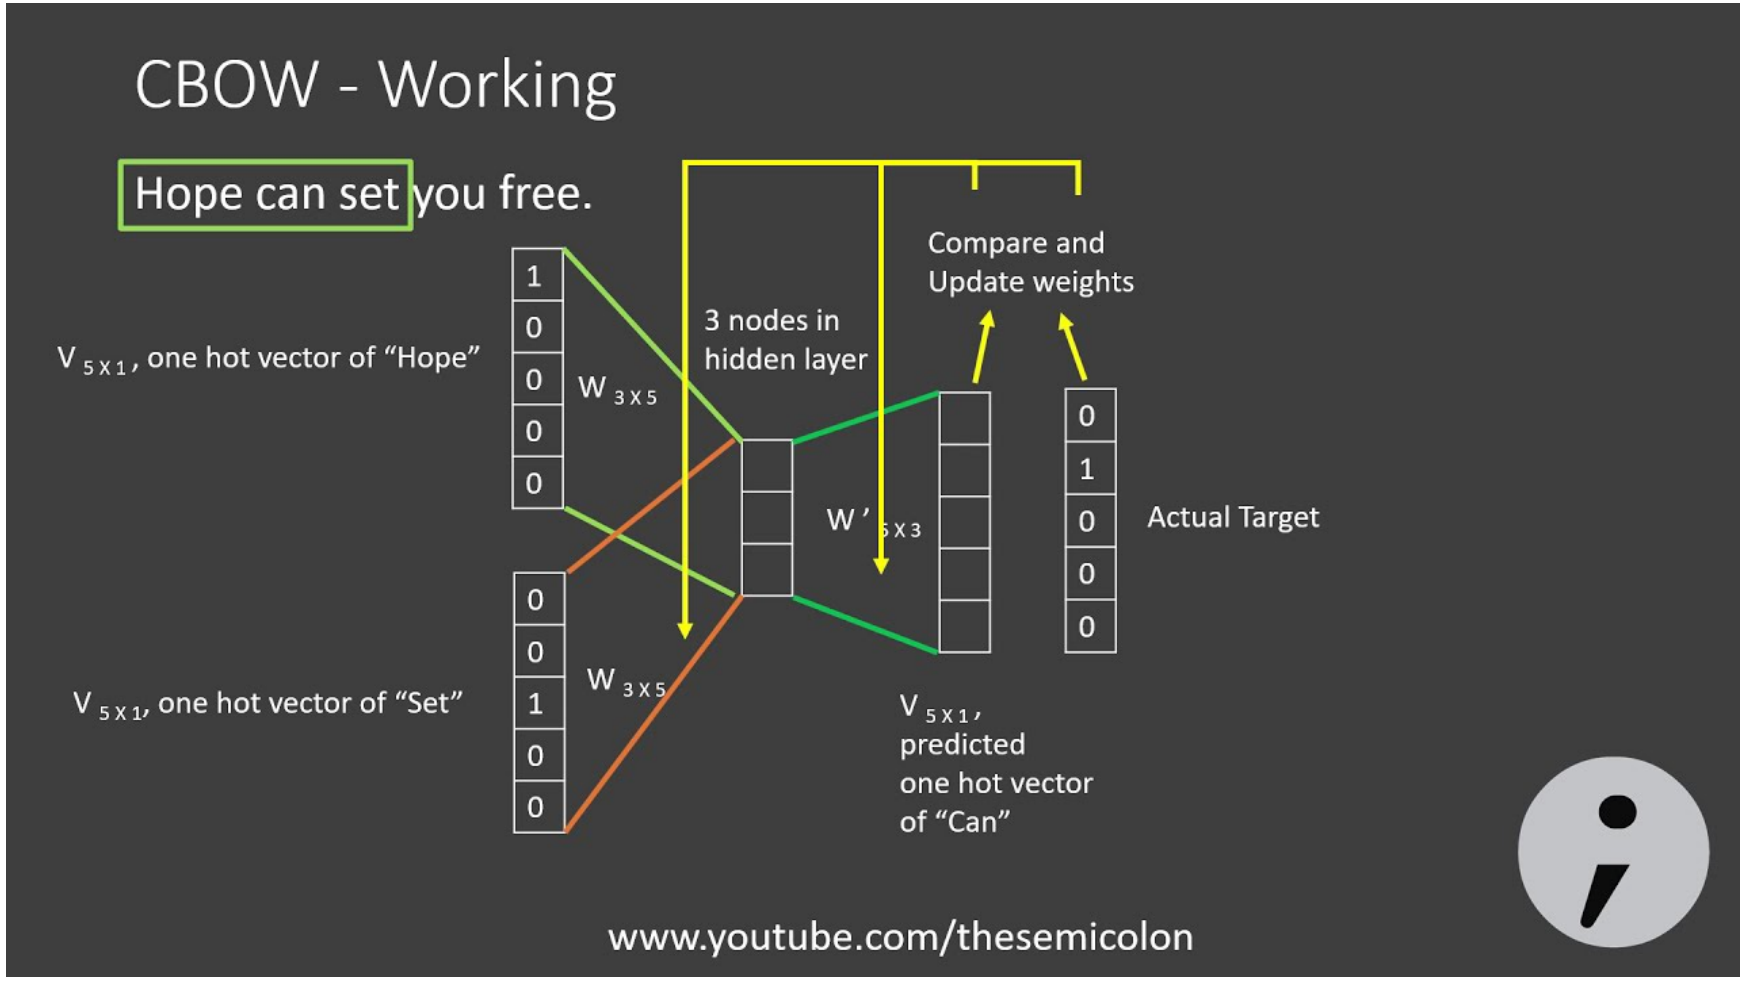

## Problème

Si l'entraînement utilise le contexte, l'encodage *one hot* n'en tient pas compte! Ainsi la phrase:

> Cet avocat pourri est mangé par un avocat pourri.

Doit-on la prendre au sens métaphorique ou littéral? *avocat* au sens de "juriste" ou d'"aliment", et *pourri* au sens de "décomposé" ou "malveillant" sont-ils les mêmes mots? Leur encodage *one hot* est pourtant le même:

| | **cet** | **avocat** | **pourri** | **est** | **mangé** | **par** | **un** |
|---|---|---|---|---|---|---|---|
| avocat | 0 | 1 | 0 | 0 | 0 | | |
| pourri | 0 | 0 | 1 | 0 | 0 | | |

## Rafinements

Des améliorations ont été apportées au modèle *word2vec* qui

- ne peut traiter que des mots qui sont dans sont lexique et pas des mots "nouveaux" -> *FastText*
- ne tient pas compte d'un contexte plus large que quelques tokens et pas du corpus -> *GloVe*

## Rafinements: FastText

Que se passe-t-il si un mot n'est pas dans cette matrice? Intuition: en le décomposant (*chantait* c'est le radicale "chant" et le morphème de l'imparfait "ai" suivi du morphème de P3 "-t") on peut gérer des mots absents du corpus d'entraînement (et améliorer les *embeddings*).

Contrairement à *GloVe* qui prend une échelle macro, celle du corpus, *FastText* prend un approche micro, au niveau du n-gramme (on parle de sous-mot).

*FastText* ne va pas utiliser des mots, mais des sous-mots:

> avocat
>
> `<av` `avo` `voc` `oca` `cat` `at>`

Attention au temps de traitement!

# Réseau de neurone pour FastText

Il reprend la même architecture que *word2vec*:

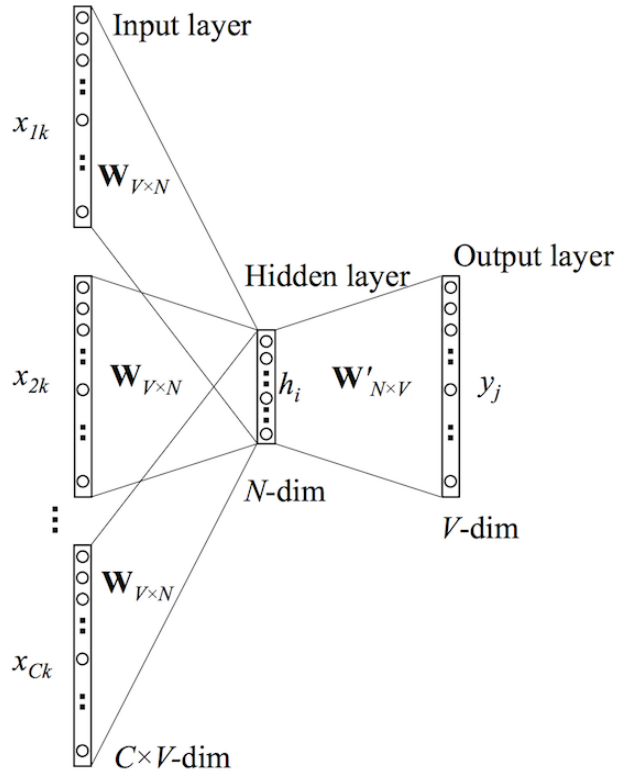


La différence est qu'en *input* et *output* on a des n-grammes.

# Rafinements: Glove

- *Glove* va pondérer la prédiction avec les statistiques de fréquence à l'échelle du corpus. Il construit une matrice de co-occurence (le nombre de mots par le nombre de context possible):

> La fondue est neuchâteloise
> La fondue est au fromage

| | La | fondue | est | neuchâteloise | au | fromage |
|---|---|---|---|---|---|---|
| La | 0 | 2 | 2 | 1 | 1 | 1 |
| fondue | | 0 | 2 | 1 | 1 | 1 |
| est | | | 0 | 1 | 1 | 1 |
| neuchâteloise | | | | 0 | 0 | 0 |
| au | | | | | 0 | 0 |
| fromage | | | | | | 0 |

# Approche par séquence

Les réseaux de neurones se complexifient. Pour les modèles que nous nous apprêtons à présenter, on s'appuie désormais sur des réseau de neurones récurrents (RNN) pour analyser des séquences.

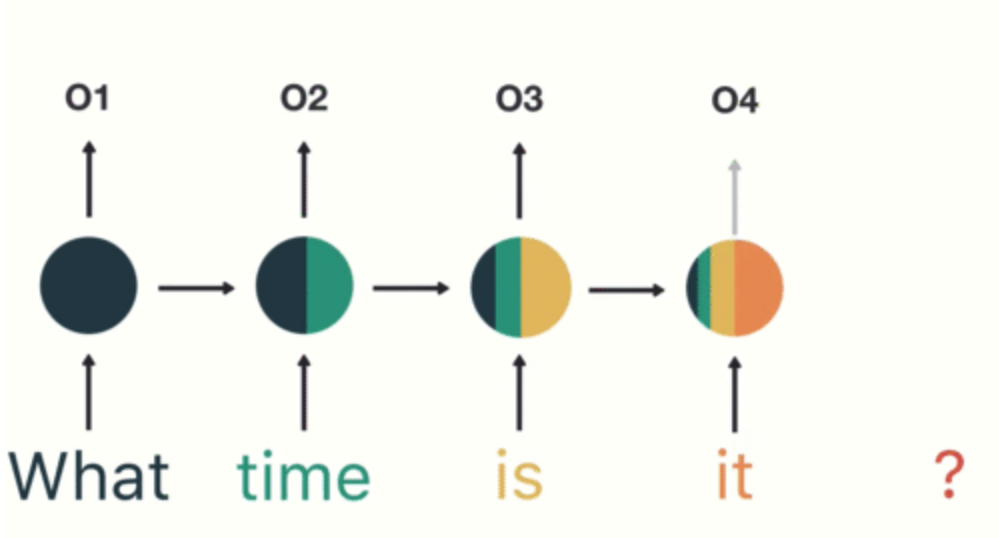


On tient compte du mot précédent de manière dynamique: plutôt qu'un contexte délimité par une fenêtre, on travaille donc de séquence à séquence (*sequence to sequence*).

# Les *embeddings* contextuels: modèle génératif

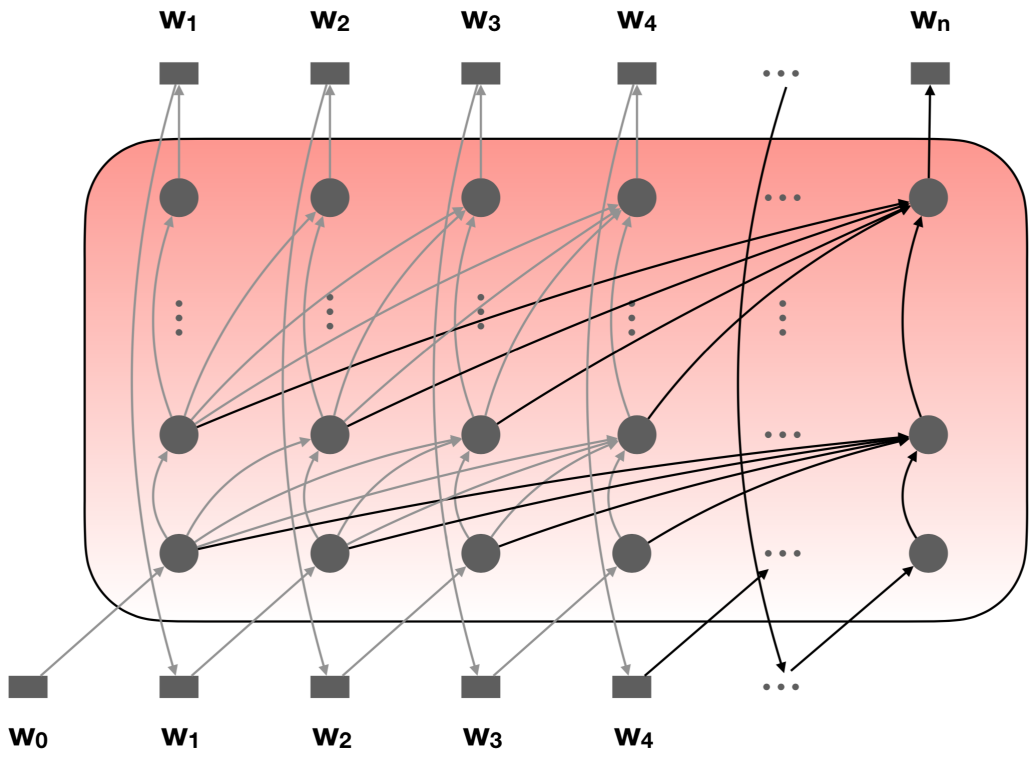


Modèle de type GPT3

# Les *embeddings* contextuels: modèle adirectionnel

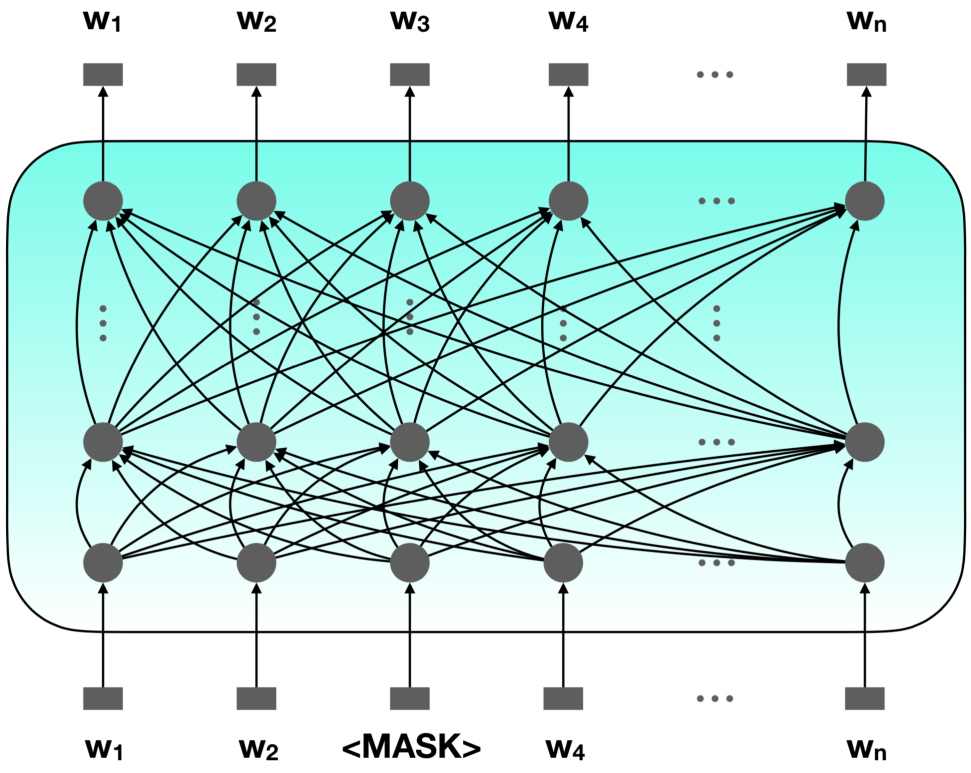


Modèle de type BERT

# Emplois

# Etudes lexicales

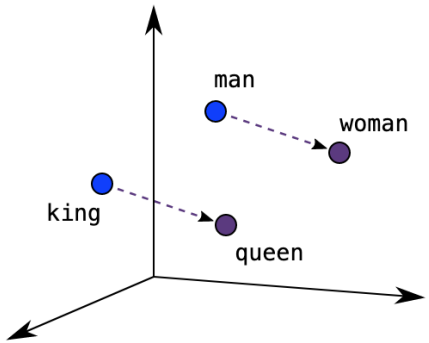


Male-Female

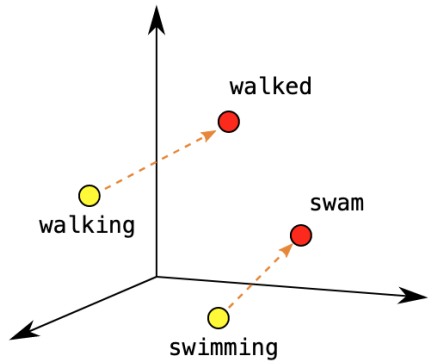


Verb Tense

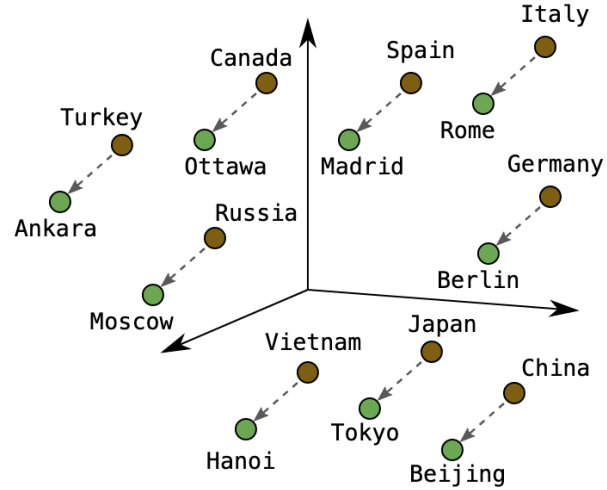


Country-Capital

# Soutien à des tâches de TAL: fournir des *embeddings*

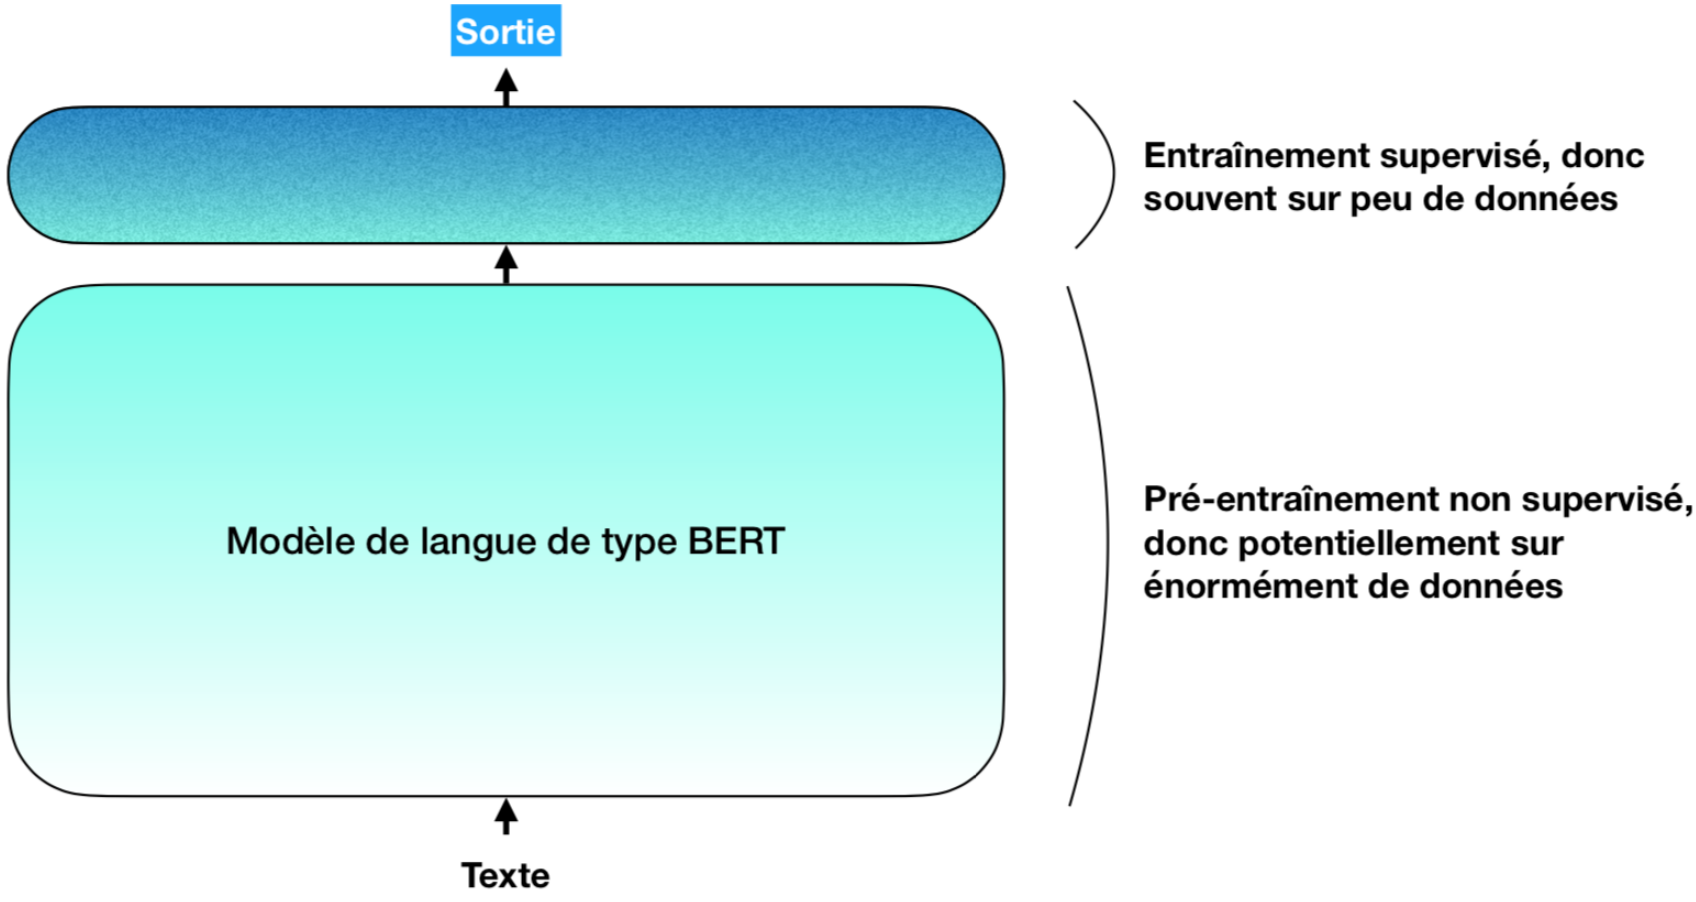

# Soutien à des tâches de TAL: fournir des *fine-tuning*

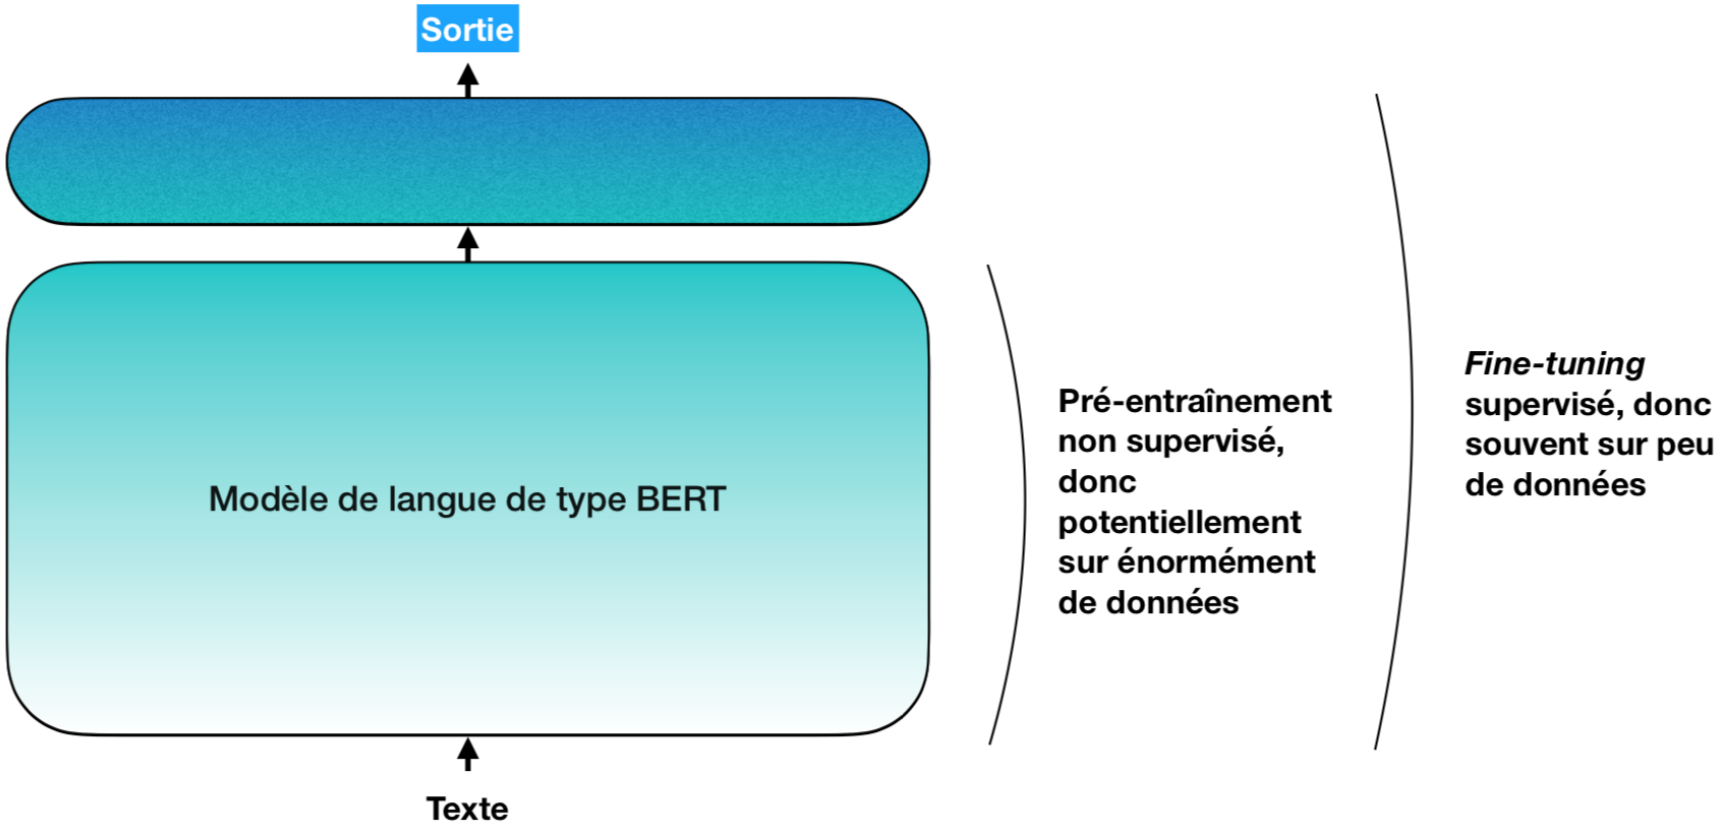


On parle donc d'entraînement semi-supervisé

# Le transformeur

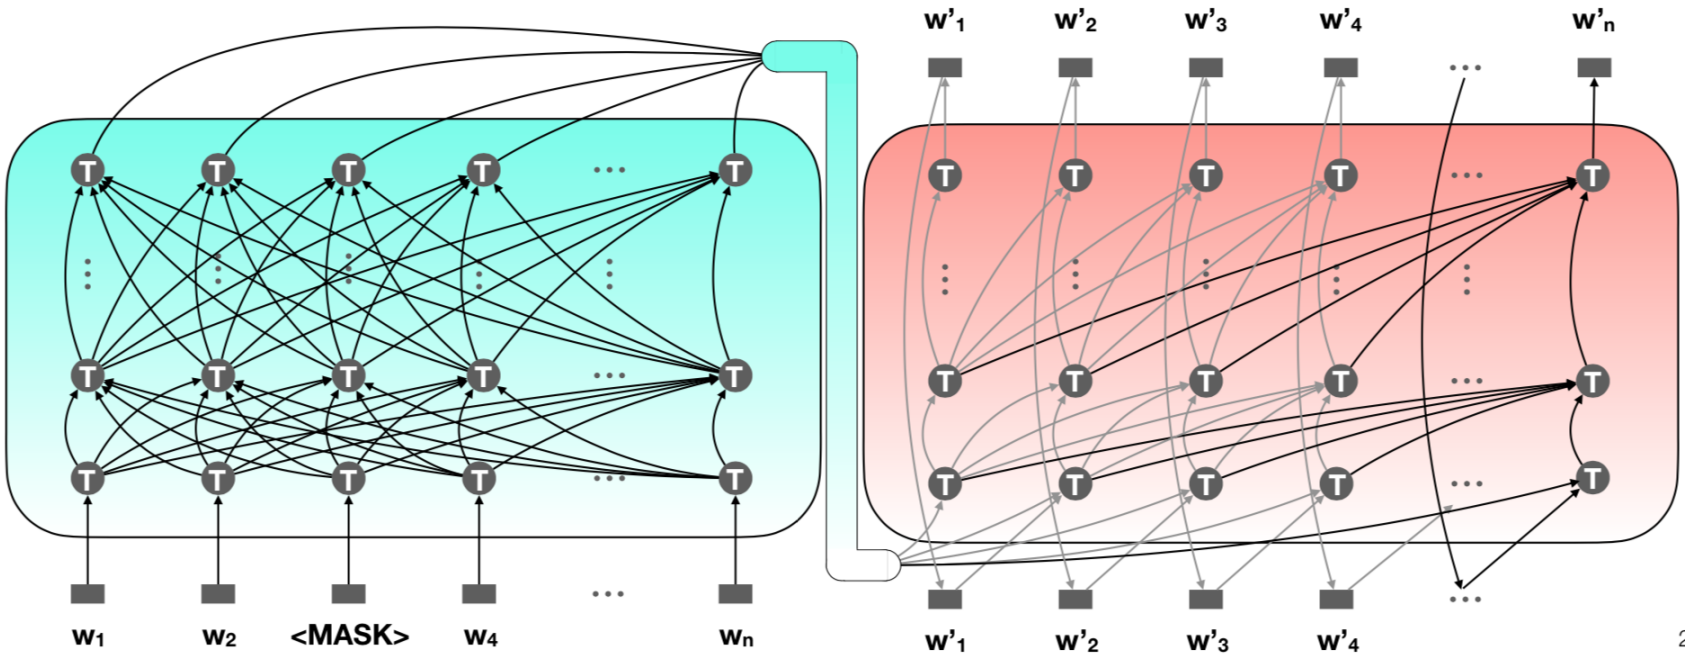


L'exemple parfait est celui de la traduction, qui nécessite d'analyser la phrase source, et de générer la phrase cible.

-> Le mécanisme d'attention permet de ne pas générer *mot à mot*.

# Mécanisme d'attention

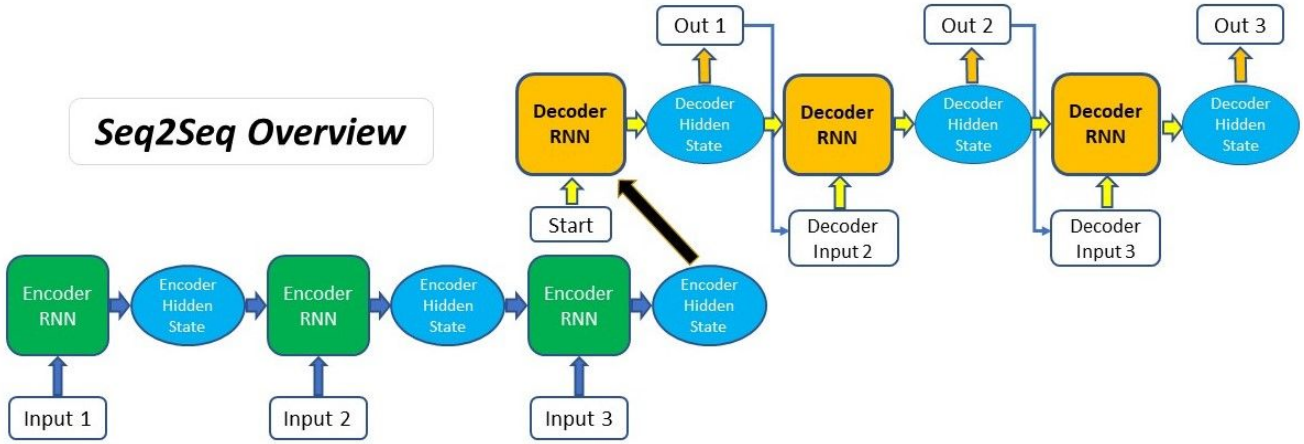


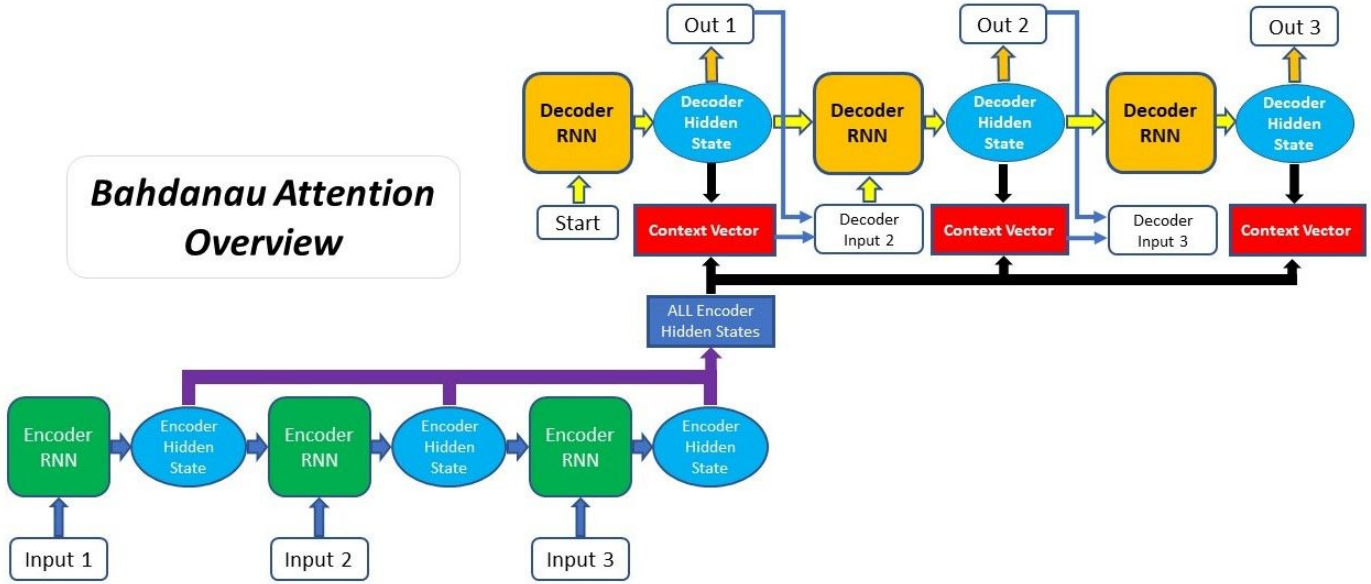

Ce cours s'inspire fortement de celui de B. Sagot donné à Genève en décemnre 2022 dans le cadre d'un atelier PDEN